Controllo ottimo Lineare Quadratico per sistemi a tempo discreto e Model Predictive Control

a.a. 2024/2025

Mario Sassano

Dipartimento di Ingegneria Civile e Ingegneria Informatica
Università di Roma Tor Vergata

Nelle lezioni precedenti...

- Abbiamo introdotto l'equazione di Bellman per determinare la Funzione Valore
- Abbiamo visto che, grazie alla Programmazione Dinamica, un problema decisionale multi-stage si può ricondurre ad un problema di ottimizzazione statica rispetto al costo dell'azione attuale più il valore migliore dello stato successivo
- Nel caso di un numero finito di scelte e di stati, abbiamo risolto l'equazione di Bellman ricorsivamente all'indietro per enumerazione completa

Alcune utili proprietà di matrici (1/2)

Matrici definite e semi-definite

Matrice $M \in \mathbb{R}^{n \times n}$, $M = M^\top$ (simmetrica) è definita positiva (semi-definita positiva) se

$$x^\top M x > 0 \quad (\geqslant 0), \forall x \in \mathbb{R}^n$$

ovvero la forma quadratica associata è una funzione sempre positiva (non-negativa)

Se M non è simmetrica..

$$x^\top M x = \frac{1}{2} x^\top (M + M + \underbrace{M^\top - M^\top}_{=0}) x = \frac{1}{2} x^\top \underbrace{(M + M^\top)}_{M_s} x + \frac{1}{2} x^\top \underbrace{(M - M^\top)}_{M_a} x$$

e

$$\frac{1}{2} x^\top M_a x = \frac{1}{2} x^\top M x - \frac{1}{2} x^\top M^\top x = 0$$

$\Rightarrow$ nella forma quadratica sopravvive solo la parte simmetrica M_s

Alcune utili proprietà di matrici (2/2)

Criterio di Sylvester

Supponiamo M simmetrica:

- M è definita positiva se e solo se (equivalentemente)
  - tutti gli autovalori di M sono positivi
  - tutti i minori[1] principali[2] dominanti[3] sono positivi
- M è semi-definita positiva se e solo se (equivalentemente)
  - tutti gli autovalori di M sono non-negativi
  - tutti i minori principali sono non-negativi

[1] sia M una matrice e $I = \{1, \ldots, m_I\}$, con k elementi e $J = \{1, \ldots, m_J\}$ con k elementi, insiemi di indici di righe e colonne, allora il minore di M corrispondente è il determinante della sotto-matrice ottenuta selezionando le righe in I e le colonne in J

[2] si parla di minore principale se $I = J$

[3] si parla di minore principale dominante di ordine k se $I = J$ e I e J contengono ordinatamente le prime k righe e colonne

Esempio di calcolo di minori

Consideriamo la matrice $M \in \mathbb{R}^{3\times 3}$

$$M = \begin{bmatrix} 1 & -1 & 2 \\ -1 & 3 & 1 \\ 2 & 1 & -1 \end{bmatrix}$$

- **minore**, $I = \{1,3\}$, $J = \{1,2\}$

$$M = \begin{bmatrix} 1 & -1 & 2 \\ -1 & 3 & 1 \\ 2 & 1 & -1 \end{bmatrix} \Rightarrow \det \begin{bmatrix} 1 & -1 \\ 2 & 1 \end{bmatrix} = 3$$

- **minore principale**, $I = \{1,3\}$, $J = \{1,3\}$

$$M = \begin{bmatrix} 1 & -1 & 2 \\ -1 & 3 & 1 \\ 2 & 1 & -1 \end{bmatrix} \Rightarrow \det \begin{bmatrix} 1 & 2 \\ 2 & -1 \end{bmatrix} = -5$$

- **minore principale dominante di ordine 2**, $I = J = \{1,2\}$

$$M = \begin{bmatrix} 1 & -1 & 2 \\ -1 & 3 & 1 \\ 2 & 1 & -1 \end{bmatrix} \Rightarrow \det \begin{bmatrix} 1 & -1 \\ -1 & 3 \end{bmatrix} = 2$$

Consideriamo un indice di costo **quadratico**

$$J(u) = \sum_{k=k_0}^{N-1} (x_k^\top Q x_k + u_k^\top R u_k) + x_N^\top S x_N$$

$Q = Q^\top \in \mathbb{R}^{n\times n}$, $Q \geqslant 0$, $R = R^\top \in \mathbb{R}^{m\times m}$, $R > 0$, $S = S^\top \in \mathbb{R}^{n\times n}$, $S \geqslant 0$
in presenza del vincolo dinamico

$$x_{k+1} = Ax_k + Bu_k, \qquad x_{k_0} = \bar{x}_0$$

sistema lineare a tempo discreto, $x_k \in \mathbb{R}^n$ e $u_k \in \mathbb{R}^m$, $k \in \mathbb{Z}$

$\Rightarrow$ valore del costo *parametrizzato* da k_0, N, $\bar{x}_0$, ovvero $J(k_0, N, \bar{x}_0, u(\cdot))$

Soluzione di ottimizzazione dinamica LQ a tempo discreto (1/4)

Per il Principio di Ottimalità:

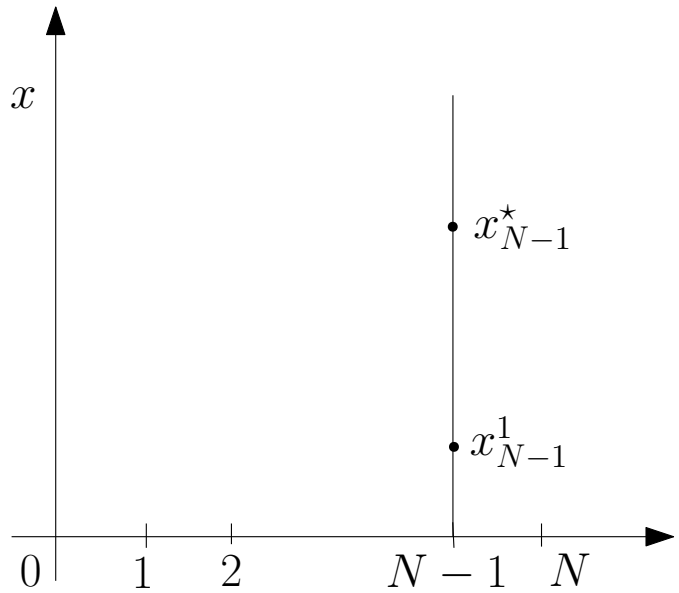
quale che sia lo stato x_{N-1} *raggiunto dal processo al tempo* $N-1$ *sotto l'azione del controllo ottimo, il valore di* u_{N-1} *(ultimo campione di controllo) che rende minimo l'intero indice di costo* J **deve essere** *tale da ottenere un costo residuo* $\tilde{J}$ *nell'intervallo* $[N-1, N]$ **minimo**

Definiamo

$$\tilde{J}(u_{N-1}) = J(N-1, N, x_{N-1}, u_{N-1}) = x_{N-1}^{\top} Q x_{N-1} + u_{N-1}^{\top} R u_{N-1} + x_N^{\top} S x_N$$

Per ricostruire ricorsivamente all'indietro la soluzione ottima, dobbiamo determinare u_{N-1} che minimizza $\tilde{J}$ quale che sia x_{N-1} (ovvero, *in funzione di* x_{N-1})

Soluzione di ottimizzazione dinamica LQ a tempo discreto (1/5)



Definiamo

$$\tilde{J}(u_{N-1}) = J(N-1, N, x_{N-1}, u_{N-1}) = x_{N-1}^\top Q x_{N-1} + u_{N-1}^\top R u_{N-1} + x_N^\top S x_N$$

Per ricostruire ricorsivamente all'indietro la soluzione ottima, dobbiamo determinare u_{N-1} che minimizza $\tilde{J}$ quale che sia x_{N-1} (ovvero, *in funzione di* x_{N-1})

Soluzione di ottimizzazione dinamica LQ a tempo discreto (2/5)

(brevissimo) riepilogo su minimizzazione non vincolata di una funzione $f(x)$

condizione necessaria $\nabla_x f(x^\star) = 0$... (esempio $f(x) = x^2$)

... ma non sufficiente... (esempio $f(x) = x^3$)

... diventa sufficiente se la matrice Hessiana di f (derivata seconda) è definita positiva

Tornando a $\tilde{J}(u_{N-1})$, sfruttiamo il processo dinamico per sostituire x_N

$$
\begin{aligned}
\tilde{J}(u_{N-1}) &= x_{N-1}^\top Q x_{N-1} + u_{N-1}^\top R u_{N-1} + x_N^\top S x_N \\
&= x_{N-1}^\top Q x_{N-1} + u_{N-1}^\top R u_{N-1} + (Ax_{N-1} + Bu_{N-1})^\top S (Ax_{N-1} + Bu_{N-1}) \\
&= x_{N-1}^\top (Q + A^\top S A) x_{N-1} + {u_{N-1}}^\top (R + B^\top S B) u_{N-1} + {u_{N-1}}^\top B^\top S A x_{N-1} \\
&\quad + x_{N-1}^\top A^\top S B u_{N-1}
\end{aligned}
$$

Soluzione di ottimizzazione dinamica LQ a tempo discreto (3/5)

Calcoliamo le derivate di $\tilde{J}$ rispetto a u_{N-1}:

$$\nabla \tilde{J} = 2(R + B^\top S B) u_{N-1} + 2B^\top S A x_{N-1}$$

$$\nabla^2 \tilde{J} = 2(R + B^\top S B)$$

Dal momento che $\nabla^2 \tilde{J} = 2(R + B^\top S B) > 0$, il minimo si ottiene imponendo $\nabla \tilde{J} = 0$

$$u^\star_{N-1} = -(R + B^\top S B)^{-1} B^\top S A x_{N-1}$$

unico valore del controllo che rende minimo $\tilde{J}$ all'istante $N-1$ in funzione di x_{N-1}

Il **valore minimo** del costo si ottiene sostituendo $u^\star_{N-1}$ in $\tilde{J}$

$$\tilde{J}^\star = x^\top_{N-1} \underbrace{(Q + A^\top S A - A^\top S B (R + B^\top S B)^{-1} B^\top S A)}_{\triangleq P_{N-1}} x_{N-1} = x^\top_{N-1} P_{N-1} x_{N-1}$$

Soluzione di ottimizzazione dinamica LQ a tempo discreto (4/5)

Il problema di calcolare $u^{\star}_{N-2}$ può essere risolto nello stesso modo **ma** u_{N-1} (così come il costo minimo ottenibile) **è già fissato** (in funzione di dove ci porterà u_{N-2}, ovvero x_{N-1})

Quindi, vogliamo minimizzare

$$\hat{J}(u_{N-2}) = x_{N-2}^{\top} Q x_{N-2} + u_{N-2}^{\top} R u_{N-2} + \underbrace{x_{N-1}^{\top} P_{N-1} x_{N-1}}_{\text{costo minimo di } u_{N-1} \text{ su } [N-1,N]}$$

simile a $\tilde{J}$ con slittamento dei tempi all'indietro di un campione $\Rightarrow$ stessa soluzione!

Soluzione di ottimizzazione dinamica LQ a tempo discreto (4/5)

Il problema di calcolare $u_k^\star$ può essere risolto nello stesso modo **ma** $u_{k+1}, u_{k+2}, \ldots, u_{N-1}$ **sono già fissati** (in funzione dello stato)

Quindi, vogliamo minimizzare

$$\hat{J}(u_k) = x_k^\top Q x_k + u_k^\top R u_k + \underbrace{x_{k+1}^\top P_{k+1} x_{k+1}}_{\text{costo minimo di } u \text{ su } [k+1,N]}$$

Iterando ricorsivamente all'indietro fino a $k_0 = 0$...

Il controllo ottimo è

$$u_k = -(R + B^\top P_{k+1} B)^{-1} B^\top P_{k+1} A x_k$$

con P calcolata ricorsivamente all'indietro da $P_N = S$ e

$$P_k = Q + A^\top P_{k+1} A - A^\top P_{k+1} B (R + B^\top P_{k+1} B)^{-1} B^\top P_{k+1} A$$

Inoltre, il costo ottimo è

$$J^\star = \bar{x}_0^\top P_0 \bar{x}_0$$

Equazione alle differenze di Riccati

Per k che va da $N-1$ a 0

$$P_k = Q + A^\top P_{k+1} A - A^\top P_{k+1} B (R + B^\top P_{k+1} B)^{-1} B^\top P_{k+1} A$$

risolta ricorsivamente *all'indietro* a partire da

$$P_N = S$$

Commenti

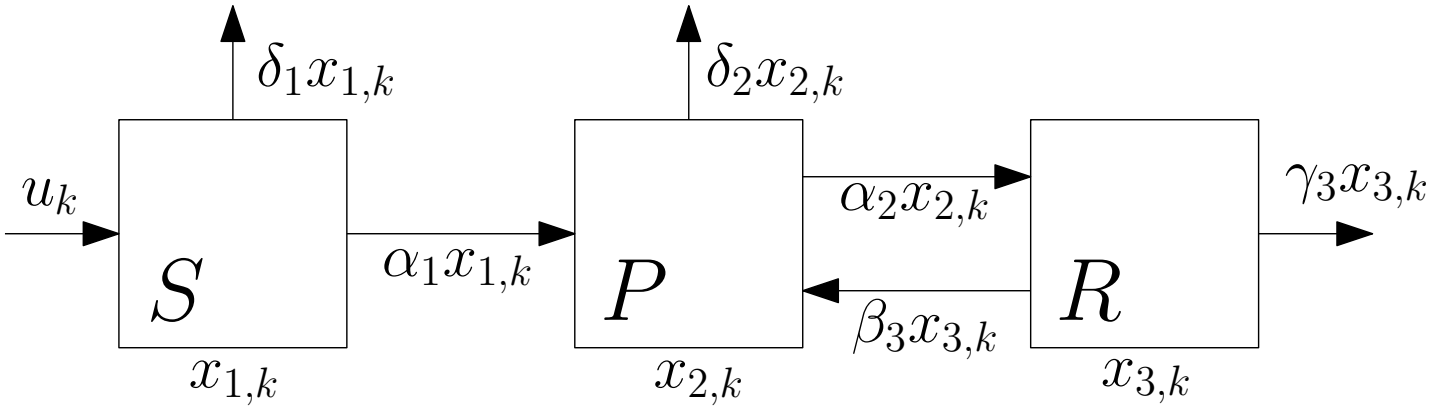
- $V_k(x_k) = x_k^\top P_k x_k$ è la **Funzione Valore** e risolve l'**Equazione di Bellman**
- L'ipotesi $Q \geqslant 0$, $S \geqslant 0$ garantisce che $(R + B^\top P_{k+1} B)$ è **definita positiva** per ogni k

  $\Rightarrow$ stiamo effettivamente calcolando un punto di minimo di $J(k, N, x_k, u_k)$!

  $\Rightarrow$ garantisce anche che $P_k \geqslant 0$, in quanto $x^\top P_k x$ descrive il valore del costo ottimo (non-negativo) da x nell'intervallo $[k, N]$

- L'ipotesi $Q \geqslant 0$, $S \geqslant 0$ può essere rilassata a patto di **verificare** che $(R + B^\top P_{k+1} B) > 0$ per ogni k

Esempio Supply Chain

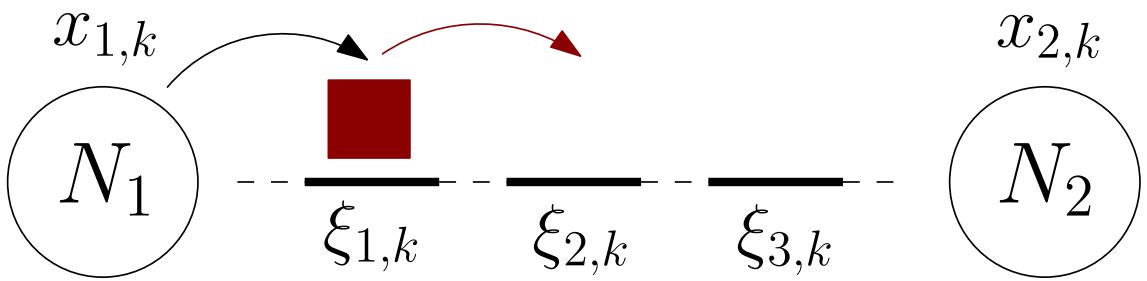


$$x_{1,k+1} = (1 - \alpha_1 - \delta_1)x_{1,k} + u_k$$
$$x_{2,k+1} = \alpha_1 x_{1,k} + (1 - \alpha_2 - \delta_2)x_{2,k} + \beta_3 x_{3,k}$$
$$x_{3,k+1} = \alpha_2 x_{2,k} + (1 - \beta_3 - \gamma_3)x_{3,k}$$
$$y_k = \gamma_3 x_{3,k}$$

Goal: massimizzare $\sum y_k$ e minimizzare $\sum u_k$

- *Supplier S* acquista una quantità u_k di materia prima ad ogni unità di tempo
- una porzione δ_1 viene scartata e una porzione α_1 viene inviata al *Producer P*
- Il Producer scarta una porzione δ_2, invia una porzione α_2 di beni prodotti al *Retailer R* e riceve una porzioni β_3 di prodotti difettosi
- Il Retailer vende una porzione γ_3 di prodotti finiti

Ritardo di trasporto in Supply Chain



Le variabili ξ modelizzano il **ritardo di trasporto**

$$\begin{cases} x_{1,k+1} = x_{1,k} - u_k \\ \xi_{1,k+1} = u_k \\ \xi_{2,k+1} = \xi_{1,k} \\ \xi_{3,k+1} = \xi_{2,k} \\ x_{2,k+1} = x_{2,k} + \xi_{3,k} \end{cases}$$

Definiamo

$$z_k := \begin{bmatrix} x_{1,k} \\ \xi_{1,k} \\ \xi_{2,k} \\ \xi_{3,k} \\ x_{2,k} \end{bmatrix} \quad \Rightarrow \quad z_{k+1} = \underbrace{\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix}}_{=:A_t} z_k + \underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}}_{=:B_t} u_k$$

Movimentazione ottima in Supply Chain

$$z_0 \text{ configurazione iniziale} \quad \Rightarrow \quad z_d \text{ configurazione desiderata}$$

z_d deve essere una configurazione di **equilibrio**, ovvero $A_t z_d = z_d$

Definiamo la **variabile di errore**

$$e_k = z_k - z_d$$

Dunque la dinamica d'errore diventa

$$\begin{aligned} e_{k+1} &= z_{k+1} - z_d = A_t z_k + B_t u_k - z_d \\ &= A_t(e_k + z_d) + B_t u_k - z_d = A_t e_k + B_t u_k + (A_t z_d - z_d) = A_t e_k + B_t u_k \end{aligned}$$

con indice di costo

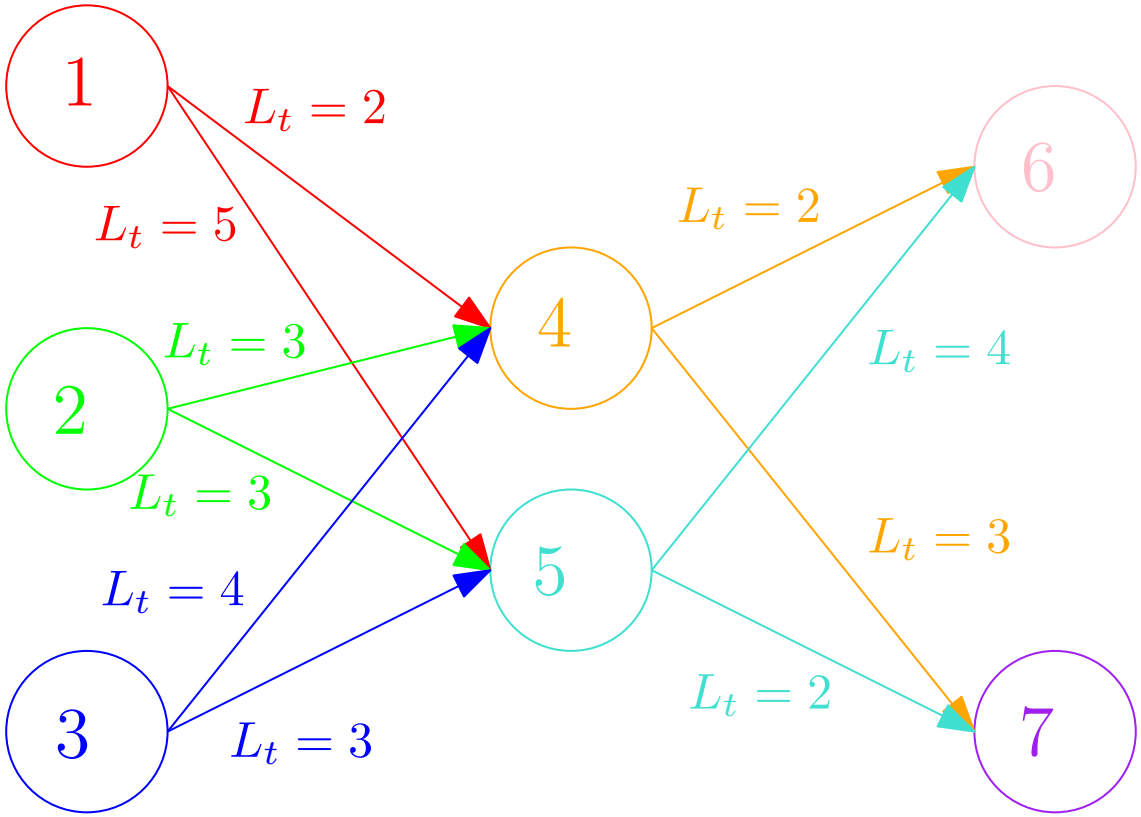
$$J(u) = \sum_{k=0}^{N-1} e_k^\top Q e_k + u_k^\top R u_k + x_N^\top S x_N$$

Risolviamo il problema di controllo ottimo nella variabile di errore, ottenendo

$$u_k^\star = -(R + B_t^\top P_{k+1} B_t)^{-1} B_t^\top P_{k+1} A_t \underbrace{(z_k - z_d)}_{=e_k}$$

$$x_0 = \begin{bmatrix} 15 & 20 & 10 & 10 & 5 & 0 & 0 \end{bmatrix}^T \quad \Rightarrow \quad x_d = \begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 40 & 20 \end{bmatrix}^T$$

$$Q = S = 10^{-3} I, R = I$$



Soluzione a "batch" di ottimizzazione dinamica LQ a tempo discreto (1/3)

Abbiamo visto come risolvere il problema di ottimizzazione dinamica in maniera **ricorsiva** all'indietro attraverso l'equazione alle differenze di Riccati

Vogliamo ora determinare l'intera **sequenza** ottima di azioni

$$U = \begin{bmatrix} u_0^\top & u_1^\top & \dots & u_{N-1}^\top \end{bmatrix}^\top \in \mathbb{R}^s$$

$s = mN$, in maniera più diretta (**esplicita**)

Dalla definizione di sistema dinamico a tempo discreto, notiamo che

$$x_1 = Ax_0 + Bu_0$$

$$x_2 = Ax_1 + Bu_1 = A(Ax_0 + Bu_0) + Bu_1 = A^2x_0 + ABu_0 + Bu_1$$

$$\vdots$$

$$x_k = A^k x_0 + \sum_{j=0}^{k-1} A^j B u_{k-1-j}$$

$\Rightarrow$ soluzione **esplicita** del sistema

Soluzione a "batch" di ottimizzazione dinamica LQ a tempo discreto (2/3)

In forma **compatta**

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} = \overbrace{\begin{bmatrix} B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ & & \ddots & \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix}}^{\triangleq \bar{S}} \begin{bmatrix} u_0 \\ u_1 \\ \vdots \\ u_{N-1} \end{bmatrix} + \overbrace{\begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix}}^{\triangleq \bar{T}} x_0 = \bar{S}U + \bar{T}x_0$$

L'indice di **costo/prestazione** può essere scritto come

$$J(U, x_0) = x_0^\top Q x_0 + \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}^\top \underbrace{\begin{bmatrix} Q & 0 & \dots & 0 \\ \vdots & \ddots & & \vdots \\ 0 & \dots & Q & 0 \\ 0 & \dots & 0 & S \end{bmatrix}}_{\triangleq \bar{Q}} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} + U^\top \underbrace{\begin{bmatrix} R & 0 & \dots & 0 \\ \vdots & \ddots & & \vdots \\ 0 & \dots & R & 0 \\ 0 & \dots & 0 & R \end{bmatrix}}_{\triangleq \bar{R}} U$$

$$= x_0^\top Q x_0 + (U^\top \bar{S}^\top + x_0^\top \bar{T}^\top)\bar{Q}(\bar{S}U + \bar{T}x_0) + U^\top \bar{R} U$$

$$= \frac{1}{2} x_0^\top \underbrace{2(Q + \bar{T}^\top \bar{Q} \bar{T})}_{\triangleq Y} x_0 + x_0^\top \underbrace{2\bar{T}^\top \bar{Q} \bar{S}}_{\triangleq F^\top} U + \frac{1}{2} U^\top \underbrace{2(\bar{R} + \bar{S}^\top \bar{Q} \bar{S})}_{\triangleq H} U$$

Soluzione a "batch" di ottimizzazione dinamica LQ a tempo discreto (3/3)

Riassumendo...

Forma "condensata" $\Rightarrow$ **Problema di minimizzazione statica non vincolata**!

$$\min_U J(U, x_0) = \frac{1}{2} U^\top H U + x_0^\top F^\top U + \frac{1}{2} x_0^\top Y x_0$$

La soluzione ottima si ottiene *azzerando* il gradiente $\nabla_U J(U, x_0) = HU + Fx_0$

$$HU^\star + Fx_0 = 0 \quad \Rightarrow \quad U^\star = \begin{bmatrix} u_0^\star \\ u_1^\star \\ \vdots \\ u_{N-1}^\star \end{bmatrix} = -H^{-1} F x_0$$

Esempio in Matlab: doppio integratore

$$x_{k+1} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} x_k + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u_k \quad \Rightarrow \quad x_{2,t} = x_{2,0} + \sum_{k=0}^{t-1} u_k, \;\; x_{1,t} = x_{1,0} + \sum_{k=0}^{t-1} x_{2,k}$$

con obiettivo di prestazione

$$J(u) = \sum_{k=0}^{N-1} \left(x_{1,k}^2 + \frac{1}{10} u_k^2 \right) + x_N^\top \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} x_N$$

Commenti su Esempio Matlab

- La soluzione "batch" non è robusta (open-loop, funzione di x_0)
- La soluzione con Riccati diventa onerosa per N grandi (ricorsione all'indietro..)
- Cerchiamo una *via di mezzo* per raggiungere il seguente obiettivo:

> *"Usare un modello* **semplificato** *(vs. dettagliato) per predire un comportamento futuro* **orientativo** *(vs. esatto) del sistema per selezionare un* **buon** *(vs. ottimo) controllo"*

Goal: $\min J(u) = \sum_{t=0}^{\infty}(x(t)^\top Q x(t) + u(t)^\top R u(t))$ *s.t.* $x(t+1) = f(x(t), u(t))$

Idea base di **Model Predictive Control** (MPC)

Ad ogni istante di tempo $t \in \mathbb{N}$:

(1) otteniamo misure aggiornate del valore dello stato corrente $x_0^{mpc} = x(t)$

(2) risolviamo un problema di ottimizzazione dinamica a "batch"[a] su una finestra di N_u passi per il modello semplificato

(3) implementiamo sul modello originale solo la prima azione ottima $u(t) = u_0^{mpc,\star}$ di $U^\star$ e scartiamo tutti i valori successivi

[a] Ad ogni istante si tratta di un problema di ottimizzazione **statica**, a cui possiamo potenzialmente aggiungere vincoli...

Strategia di MPC

Da questa slide, per semplicità: $x_k^{mpc} \to x_k$, $u_k^{mpc} \to u_k$!

Ad ogni istante di tempo $t \in \mathbb{N}$:

Modello di predizione

$$x_{k+1} = Ax_k + Bu_k, \quad x_0 = x(t)$$

$$y_k = Cx_k$$

$x_k \in \mathbb{R}^n$, $u_k \in \mathbb{R}^m$, $y_k \in \mathbb{R}^p$

Vincoli

$$u_{min} \leqslant u_i(t) \leqslant u_{max}, \quad i = 1, \ldots, m$$

$$\Rightarrow u_{min} \leqslant u_{i,k} \leqslant u_{max}, k \in [0, N_u - 1]$$

$$y_{min} \leqslant y_j(t) \leqslant y_{max}, \quad j = 1, \ldots, p$$

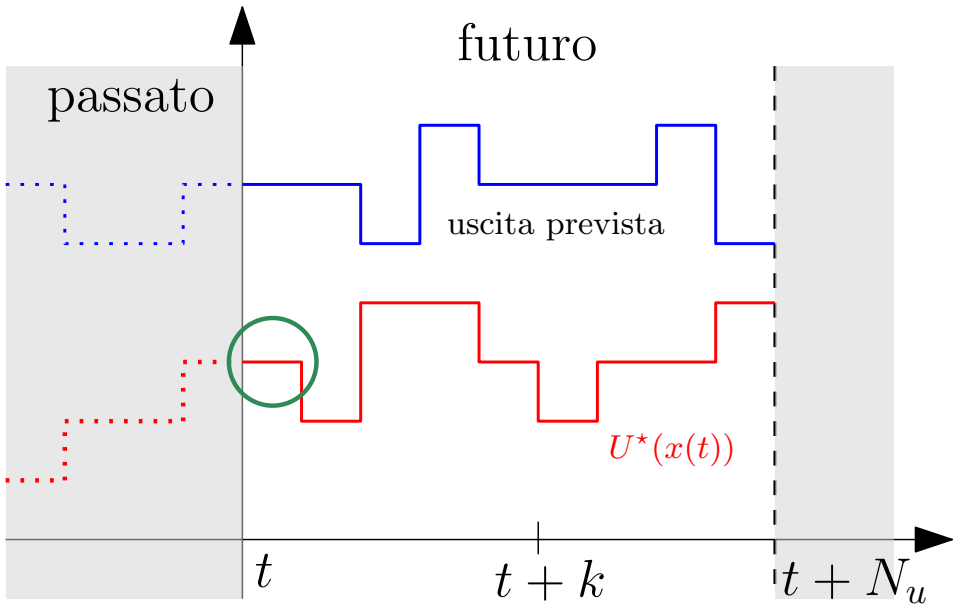
$$\Rightarrow y_{min} \leqslant y_{j,k} \leqslant y_{max}, k \in [0, N_u]$$

Indice di prestazione (a "finestra mobile")[a]

$$V(x_0) = \min_u \sum_{k=0}^{N_u-1} (x_k^\top Q x_k + u_k^\top R u_k) + x_{N_u}^\top S x_{N_u}$$

Notazione:

- $x(t)$: campione corrente dello stato
- $x_k = x(t+k|t)$: evoluzione prevista dal modello *data* l'informazione all'istante t
- $u_k = u(t+k|t)$: azione da eseguire all'istante $t+k$ *data* l'informazione a t



[a] Possiamo aggiungere un costo "terminale" virtuale...

Vincoli sul controllo[4]

$$\begin{cases} u_{i,k} & \leqslant & u_{max} \\ -u_{i,k} & \leqslant & -u_{min} \end{cases} \Rightarrow \begin{bmatrix} I_m & 0 & \dots & 0 \\ 0 & I_m & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & \dots & 0 & I_m \\ -I_m & 0 & \dots & 0 \\ 0 & -I_m & \dots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & \dots & 0 & -I_m \end{bmatrix} U \leqslant \begin{bmatrix} u_{max} \cdot \mathbb{1}_m \\ u_{max} \cdot \mathbb{1}_m \\ \vdots \\ u_{max} \cdot \mathbb{1}_m \\ -u_{min} \cdot \mathbb{1}_m \\ -u_{min} \cdot \mathbb{1}_m \\ \vdots \\ -u_{min} \cdot \mathbb{1}_m \end{bmatrix}$$

Vincoli sull'uscita, ricordando che $y_k = CA^k x_0 + \sum_{i=0}^{k-1} CA^i B u_{k-1-i}$

$$y_{k,i} \leqslant y_{max} \Rightarrow \begin{bmatrix} CB & 0 & \dots & 0 \\ CAB & CB & \dots & 0 \\ \vdots & & \ddots & \vdots \\ CA^{N_u-1}B & \dots & CAB & CB \end{bmatrix} U \leqslant \begin{bmatrix} y_{max} \cdot \mathbb{1}_p \\ y_{max} \cdot \mathbb{1}_p \\ \vdots \\ y_{max} \cdot \mathbb{1}_p \end{bmatrix} - \begin{bmatrix} CA \\ CA^2 \\ \vdots \\ CA^{N_u} \end{bmatrix} x_0$$

$\Rightarrow$ relazione simile per $-y_{k,i} \leqslant -y_{min}$

[4] Se $v \in \mathbb{R}^n$ e $w \in \mathbb{R}^n$ sono due vettori della stessa dimensione, la notazione $v \leqslant w$ si intende componente per componente, $v_i \leqslant w_i$, $i = 1, \dots, n$. La notazione $\mathbb{1}_h$ indica il vettore $\mathbb{1}_h = [1, 1, \dots, 1]^\top \in \mathbb{R}^h$, mentre I_h denota la matrice identità $h \times h$.

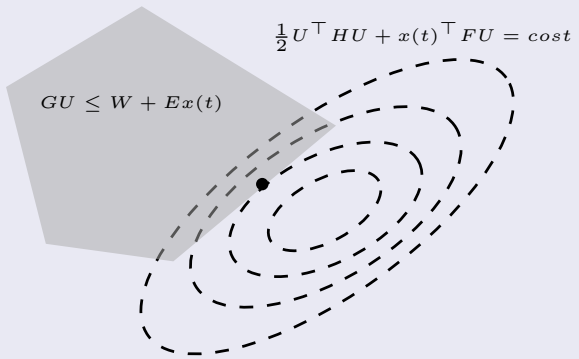
Model Predictive Control in presenza di vincoli → batch. necessariamente

Ad ogni istante di tempo $t \in \mathbb{N}$:

(1) otteniamo misure aggiornate del valore dello stato corrente $x(t)$

(2) determiniamo la soluzione del problema di Programmazione Quadratica:

$$(QP) := \begin{cases} \overbrace{\min_U \left\{ \frac{1}{2} U^\top H U + x(t)^\top F^\top U \right\} + \frac{1}{2} x(t)^\top Y x(t)}^{:= V^\star(x(t))} \\ \text{s.t.} \quad GU \leqslant W + \underbrace{Ex(t)}_{\text{feedback}} \end{cases}$$



(3) implementiamo solo la prima azione ottima $u(t) = u_0^\star$ di $U^\star$

QP convesso:

- funzione obiettivo quadratica (convessa con $R > 0$)
- vincoli lineari[5] $GU \leqslant W + Ex(t)$ definiscono un *poliedro*[6]

[5] Le matrici G, W ed E si ricavano direttamente dai vincoli compatti della slide precedente.

[6] Un sotto-insieme $\mathcal{P}$ di $\mathbb{R}^n$ è detto poliedro se è dato dall'intersezione di un numero finito di semi-piani chiusi $\mathcal{P} = \{x \in \mathbb{R}^n : p_i^\top x \leqslant \alpha_i, i = 1, \ldots, r, p_i \in \mathbb{R}^n, \alpha_i \in \mathbb{R}\}$.

Esempio del doppio integratore rivisitato

Consideriamo il problema di ottimizzazione dinamica con indice di prestazione

$$J(u) = \sum_{t=0}^{\infty} y(t)^2 + \frac{1}{10} u(t)^2$$

con vincolo dinamico (**doppio integratore**)

$$x(t+1) = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} x(t) + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u(t), \quad y(t) = \begin{bmatrix} 1 & 0 \end{bmatrix} x(t)$$

e vincoli sul controllo

$$-1 \leqslant u(t) \leqslant 1$$

$\Rightarrow$ **Utilizziamo lo schema di MPC con** $N_u = 2$ **e** $S = I$ (matrice identità), ovvero

$$J_{\mathrm{MPC}}(u) = \sum_{k=0}^{1} y_k^2 + \frac{1}{10} u_k^2 + x_2^{\mathsf{T}} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} x_2$$

3 aspetti da considerare: ammissibilità, stabilità e complessità computazionale

NON DISTRUGGO IL SISTEMA IN ESAME

TUTTI I PROBLEMI A BATCH DEVONO ESSE AMMISSIBILI (RICORSIVAMENTE)

Vincolo di stabilità per MPC

Consideriamo il sistema lineare $x(t+1) = Ax(t) + Bu(t),\ t = 0, 1, \ldots$ e supponiamo che la strategia di MPC sia basata sul seguente problema QP:

su Δ $\quad$ su $[t, t+N_u]$

Σ_R e Σ_C sono lineari per semplicità della dimostrazione (cambia l'app. della finestra di ottimizzazione)

$$V^\star(x(t)) = \min \sum_{k=0}^{N_u-1} (x_k^{mpc})^\top Q x_k^{mpc} + (u_k^{mpc})^\top R u_k^{mpc}$$

$$\text{s.t. } x_{k+1}^{mpc} = Ax_k^{mpc} + Bu_k^{mpc},\ x_0^{mpc} = x(t)$$

$$u_{min} \leqslant u_k^{mpc} \leqslant u_{max} \quad (\Sigma_S) \quad (\Sigma_R)$$

$$y_{min} \leqslant Cx_k^{mpc} \leqslant y_{max}$$

$$x_{N_u}^{mpc} = 0 \quad \text{(vincolo terminale!)}$$

GARANTISCE CHE I PROBLEMI SONO AMMISSIBILI

$\rightarrow$ x_{t+N_u} non sarà necess. 0 (ho controlli diversi).

con $Q > 0$, $R > 0$, $u_{min} < 0 < u_{max}$ e $y_{min} < 0 < y_{max}$. Allora, **se il problema QP è ammissibile al tempo** $t = 0$,

(Asintotico sul Σ_R)

$$\lim_{t\to\infty} x(t) = 0, \quad \lim_{t\to\infty} u(t) = 0$$

e i vincoli sono soddisfatti per ogni t.

(scelto da noi)

0 è il comp. nominale (potrei mettere una traslazione per portare il sistema dove voglio) o

$\Sigma_R \equiv \Sigma_S$ coincidono e $x_{N_u}^{mpc} = 0$ sono cond. suff. ma non necessarie

Come sostituisco il "vincolo hard" $x_{N_u}^{npc} = 0$?

↓

Lo metto nella funzione obiettivo come

$$\underbrace{(x_{N_u}^{npc})^T \cdot S \, (x_{N_u}^{npc})}$$

vincolo soft che porta $x_{N_u}^{npc} = 0$ ∀ finestra temporale se S è suff. "pesante"

$S \in \mathbb{R}^{m \times m}$

Dimostrazione di stabilità per MPC con vincolo terminale (1/3)

Per induzione

sarà applicabile sul sistema semplificato

- Supponiamo che $U_t^\star = [u_0^t, \ldots, u_{N_u-1}^t]$ sia la soluzione ottima di QP al tempo t con valore ottimo $V^\star(x(t))$
- Dato che $U_t^\star$ è ammissibile, sappiamo che $x(t+N_u|t) = x_{N_u}^{mpc} = 0$ (vincolo terminale)

poiché ottima

$$\Sigma_S \begin{cases} x_1^{mpc} = A\overbrace{x_0^{mpc}}^{x(t)} + Bu_0^t \\ x_2^{mpc} = Ax_1^{mpc} + Bu_1^t \\ \vdots \\ \underbrace{0}_{x_{N_u}^{mpc}} = Ax_{N_u-1}^{mpc} + Bu_{N_u-1}^t \end{cases}$$

per effetto del vincolo terminale di stabilità

Dimostrazione di stabilità per MPC con vincolo terminale (2/3)

$[1, N_u]$ è la nuova finestra

- Di conseguenza, la sequenza $U_{t+1} = [u_1^t, \ldots, u_{N_u-1}^t, 0]$ è ammissibile per QP al tempo $t+1$. Infatti:
  - $u(t) = u_0^t \implies \overbrace{x(t+1)}^{\text{quella vera}} = x(t+1|t) = x_1^{mpc}$ ← questo perché Σ_S e Σ_R coincidono.
  - la sequenza U_{t+1} è tale che

Nu passi su $\Sigma_S (\equiv \Sigma_R)$

$$
\begin{cases}
\cancel{x_1^{mpc} = Ax_0^{mpc} + Bu_0^t} & \\
x_2^{mpc} = Ax_1^{mpc} + Bu_1^t & (1) \\
\vdots & \\
0 = Ax_{N_u-1}^{mpc} + Bu_{N_u-1}^t & (N_u-1) \\
\underbrace{0}_{x_{N_u+1}^{mpc}} = A \cdot 0 + B \cdot 0 & (N_u)
\end{cases}
$$

(QP_{t+1}) è ammissibile

$[u_1^t, \ldots, u_{N_u-1}^t, 0]$ è ammi-

$\Rightarrow$ implicando la **ammissibilità** ricorsiva

Dimostrazione di stabilità per MPC con vincolo terminale (3/3)

(*) $\Rightarrow$ l'ultimo controllo della seq. è banale.

- Il costo di U_{t+1} è

  non lo guardo perché passato

  (*) (0) $+ \; V^\star(x(t)) - x(t)^\top Q x(t) - u(t)^\top R u(t) \geqslant V^\star(x(t+1))$

  ovviamente maggiore del valore ottimo a $t+1$, ovvero $V^\star(x(t+1))$

  $\Rightarrow$ $V^\star(x(t))$ è monotonicamente decrescente e limitata inferiormente ($V(x(t)) \geqslant 0$)

  $\Rightarrow \exists \lim_{t\to\infty} V^\star(x(t)) =: V_\infty$

  costante e >0

  ricorsivamente capisco che $V^*(x(t))$ è monotona

- Dunque

$$0 \leqslant x(t)^\top Q x(t) + u(t)^\top R u(t) \leqslant V^\star(x(t)) - V^\star(x(t+1)) \to 0, \text{ per } t \to \infty$$

  e la tesi segue dal fatto che Q ed R sono matrici definite positive

$x^T(t) Q x(t) \geq 0$

$u^T(t) R u(t) > 0$

$0 \leq x(t)^T Q x(t) + u(t)^T R u(t) \leq 0$ Th. dei carabinieri.

MPC per sistemi nonlineari - formulazione

Voglio un vincolo lineare per garantire convessità

Consideriamo il sistema **nonlineare**

$$x(t+1) = f(x(t), u(t))$$

semplifico il sistema.

con **indice di costo** (quadratico)

su un costo su $[0, \infty]$

$$J(x,u) = \sum_{t=0}^{\infty} x(t)^\top Q x(t) + u(t)^\top R u(t)$$

e **vincoli** sull'azione di controllo

$$(*) \quad \left(u_{min} \leq u(t) \leq u_{max}, \right) \qquad \forall t$$

più o meno forza

Nel MPC risolvendo iterativamente dei problemi a batch posso inserire dei vincoli come questi (*).

↳ OTT. STATICA SU UN PROBLEMA QUADRATICO CON VINCOLI LINEARI.

MPC per sistemi nonlineari - modello approssimato

Consideriamo la **condizione corrente** del sistema (x_c, u_c) — u_c: implementato all'istante precedente

Modello approssimato con espansione di Taylor al primo ordine a $(x(t), u(t)) = (x_c, u_c)$ — troncato ordine superiore

$$x(t+1) \approx f(x_c, u_c) + \underbrace{\left.\frac{\partial f}{\partial x}\right|_{(x_c,u_c)}}_{\triangleq A_a} \overbrace{(x(t) - x_c)}^{\triangleq \delta x(t)} + \underbrace{\left.\frac{\partial f}{\partial u}\right|_{(x_c,u_c)}}_{\triangleq B_a} \overbrace{(u(t) - u_c)}^{\triangleq \delta u(t)}$$

PESO LA DER SU INCREMENTO

Per definizione di δx abbiamo che $x(t+1) = \underbrace{\delta x(t+1)}_{\text{incremento}} + x_c$, quindi

$$\delta x(t+1) = A_a \delta x(t) + B_a \delta u(t) + \underbrace{f(x_c, u_c) - x_c}_{\triangleq P_a}$$

vettore

Incremento di $x(t+1)$ è un sistema quasi lineare.

$\Rightarrow$ sistema **affine** ($P_a \neq 0$ in generale) nelle variabili di variazione $\delta x, \delta u$

$\left.\frac{\partial f}{\partial x}\right|_{(x_c,u_c)}$ $\longrightarrow$ JACOBIANA DELLA MAPPA f PARAMETRIZZATA SU (x_c, u_c) $\}$ (MATRICE) A_a

è UNA COSTANTE!

$P_a = 0$ sse x_c è un p.to di lavoro

$$x_c = f(x_c, u_c) \quad \exists\ x_c, u_c \text{ che non annullano}$$

Per piccole variazioni della x approx. un sistema non lineare con uno lineare.

↓

In generale $P_a \neq 0$ (x_c non è un equilibrio) e approx. per piccole variazioni il sistema non lineare con uno affine.

↑

Piccole variazioni = piccola finestre temporale

Se N_u aumento ho un aumento di complessità e una diminuzione dell' approx ⇒ N_u troppo lunga perde anche il vantaggio dell' accuratezza previsionale

MPC per sistemi nonlineari - algoritmo → trovo un sottomo

Dato $x(t+1) = f(x(t), u(t))$, $x(0) = x_0$ fissiamo $u_c = u_0$

While $t \geq 0$

1. **Misuriamo** lo stato corrente del sistema $x_c = x(t)$
2. **Costruiamo** il sistema approssimato

sistema affine

$$\begin{cases} \delta x(k+1) = A_a(x_c, u_c)\delta x(k) + B_a(x_c, u_c)\delta u(k) + P_a(x_c, u_c), \\ \delta x(0) = 0 \end{cases}$$

scostamento iniz. nullo

con $\delta x(k) = x(t+k) - x_c$ $\quad x(t+k) = \delta x(k) + x_c$ ← stima di x (Σp) con piccole variazioni

3. **Risolviamo** un problema di controllo ottimo rispetto a δu (VARIAZIONI)

$$J(x_c + \delta x, u_c + \delta u) = \sum_{k=0}^{N_u-1} (x_c + \delta x(k))^\top Q(x_c + \delta x(k)) + (u_c + \delta u(k))^\top R(u_c + \delta u(k))$$
$$+ (x_c + \delta x(N_u))^\top S(x_c + \delta x(N_u))$$

4. **Poniamo** $x(t+1) = f(x(t), u_c + \delta u^\star(0))$, $t \leftarrow t+1$ e $u_c \leftarrow u_c + \delta u^\star(0)$

assegnazione

end

implemento sempre e solo il seguente.

Controllo di Modello SIR - Esercitazione Matlab

(PRODOTTO STATO-STATO E CONTROLLO-STATO $x(t+1) = f(x_t, u_t)$

$t \xrightarrow{1} t+1$

Consideriamo il seguente **modello epidemiologico** (SIR) → MODELLO COMPARTIMENTALE: evoluzione delle popolazioni tra una categoria e un'altra

$$\#\ \text{suscettibili} \longleftarrow S(t+1) = S(t) - \frac{u(t)\tau}{\text{pop}} S(t) I(t)$$

Se $I(t) \uparrow$ $S(t+1) \downarrow$; tanti suscettibili e tanti infetti causano tanti contagi e riduce i suscettibili

Se $S(t) \uparrow$ $S(t+1) \downarrow$

$$\#\ \text{infetti} \longleftarrow I(t+1) = I(t) + \frac{u(t)\tau}{\text{pop}} S(t) I(t) - \nu I(t)$$

$$\#\ \text{di guariti "recovered"} \longleftarrow R(t+1) = R(t) + \nu I(t)$$

con

- $S(t)$ suscettibili, $I(t)$ infetti, $R(t)$ *recovered*, pop popolazione totale

  $\Rightarrow S(t+1) + I(t+1) + R(t+1) = S(t) + I(t) + R(t) = \text{pop}$ vincolo di conservazione

  $\Rightarrow x(t) = \begin{bmatrix} S(t) & I(t) & R(t) \end{bmatrix}^\top$
- ν, tasso di guarigione
- τ, tasso di trasmissibilità } collaborare
- $u(t)$, numero di contatti al passo t

$\frac{u(t)}{\text{pop}}$ → quanti suscettibili e infetti vengono a contatto $\left[u(t)/\text{pop} = P_\phi\right]$

$u(t) = 0 \Leftrightarrow$ no contatti

$\vdots$

$u(t) = h$ # contatti

Esercitazione/Progetto Matlab

"cons. massa"
$\sum_i x_i(t) = 65000 \quad \forall \; t.$

Consideriamo il modello SIR con $\tau = 2/10$, $\nu = 1/15$

$$x(0) = \begin{bmatrix} 45000 & 1 & 14999 \end{bmatrix}^T \quad \rightarrow \quad x_d = \begin{bmatrix} 0 & 0 & 60000 \end{bmatrix}^T$$

parente $\emptyset$

e l'indice di prestazione

"TRY AND ERROR" SUI PARAMETRI LIBERI

VOGLIO CONTENERE IL COSTO + POSSIBILE $\longrightarrow$

BILANCIO IL COSTO

$$J(x,u) = \sum_{t=0}^{\infty} 10^{-2} I(t)^2 + (u(t) - 8)^2$$

SPOSTARE LA $u(t)$ DA 8 "VALORE NOTURNA" LE SOLAMENTE UTILE" HA UN COSTO

con il vincolo

$$0 \leq u(t) \leq 20$$

Vediamo prima cosa succede se $u(t) = 8 \quad \forall \; t$

MPC implicito vs MPC esplicito.

$$(QP) \quad \begin{cases} V(x(t)) = \min\limits_{U} \left\{ \frac{1}{2} U^\top H U + x(t)^\top F^\top U \right\} + \frac{1}{2} x(t)^\top Y x(t) \\ \text{s.t.} \quad GU \leqslant W + Ex(t) \end{cases}$$

- Ottimizzazione On-line: dato $x(t)$ risolviamo il problema ad ogni tempo $t \in \mathbb{N}$

  ABBIAMO VISTO QUESTO

  zero costo di memoria ma online

  $\Rightarrow$ la legge di controllo $u = u_0^\star$ è funzione **implicita** di $x(t)$

  $\Rightarrow$ problema di Programmazione Quadratica (QP)

  VIENE CALCOLATA IN BASE A $x(t)$ MA NON HO F.NE ESPLICITA DI $u(x(t))$.

  [DEVO RISOLVERE IL PROBLEMA CHE SE HA VINCOLI È BRUTALE]

- Ottimizzazione Off-line: risolviamo il problema QP *a priori* per ogni $x(t)$ in un dato insieme

  SI FA NELLA PRATICA

  $\Rightarrow$ la legge di controllo $u = u_0^\star(x(t))$ è funzione **esplicita** di $x(t)$

  $\Rightarrow$ QP multi-parametrico (mp-QP)!

  RISOLVO QP PARAMETRICO E TROVO $u = u_0^*(x(t))$

  NON POSSO RISOLVERE $\forall\, x(t)$ MA SOLO PER ALCUNI E MI SERVE UNA PARAMETRIZZATA OPPORTUNA

  COSTO COMPUTAZIONALE ELEVATO (E ANCHE DI MEMORIA) MA ONLINE SONO RAPIDO

mp-QP

Dato il problema di ottimizzazione

$$\min_z f(z, x) \qquad x \in \mathbb{R}^n$$
$$\text{s.t. } g(z, x) \leqslant 0 \qquad z \in \mathbb{R}^s$$

e un insieme $X \subseteq \mathbb{R}^n$ di parametri x di interesse, determinare:

- insieme dei **parametri ammissibili** $X^\star \subseteq X$ per i quali il problema ammette soluzione
- **funzione valore** $V^\star : X^\star \to \mathbb{R}$ che associa il valore ottimo a ciascun $x \in X^\star$
- una **funzione ottimizzante** $z^\star : X^\star \to \mathbb{R}^s$ che associa la soluzione ottima a ciascun $x \in X^\star$

Q1. Che struttura hanno $V^\star$ e $z^\star$ in funzione di x nel caso del mp-QP per MPC?

Q2. Come possiamo determinare $V^\star$ e $z^\star$ in maniera *efficiente*?

Funzione *affine a tratti*

Una funzione $U(x) : X \mapsto \mathbb{R}^s$, dove $X \subseteq \mathbb{R}^n$ è un poliedro, è **affine a tratti** se è possibile partizionare X in regioni poliedrali convesse CR_i e tali che

$$U(x) = H^i x + k^i$$

per ogni $x \in CR_i$. ◦

Come **passo preliminare** per l'algoritmo, introduciamo

$$z = U + H^{-1} F x(t)$$

$\Rightarrow$ problema mp-QP diventa:

$$\text{mp} - \text{QP}_z := \begin{cases} V_z(x) = \min_z \frac{1}{2} z^\top H z & \Leftrightarrow \quad V(x) = V_z(x) + \frac{1}{2} x^\top (Y - F^\top H^{-1} F) x \\ \text{s.t. } Gz \leqslant W + Mx & \Leftrightarrow \quad M = E + G H^{-1} F \end{cases}$$

Infatti, sostituendo la z nel costo...

$$V_z = \frac{1}{2}(U^\top + x^\top F^\top H^{-1}) H (U + H^{-1} F x) = \frac{1}{2} U^\top H U + \frac{1}{2} x^\top \overbrace{F^\top H^{-1} F}^{\text{"al posto di" } Y} x + \frac{1}{2} U^\top F x + \frac{1}{2} x^\top F^\top U$$

Struttura della soluzione ottima di mp-QP$_z$ (1/2)

Dati:

- un **insieme poliedrale** $X := \{x : Tx \leqslant Z\}$ di parametri per cui risolvere mp-QP$_z$
  $\Rightarrow$ ad esempio, *box-set*: $\underline{x}_i \leqslant x_i \leqslant \bar{x}_i$ per ogni componente
- un **vettore iniziale** $x_0 \in X$ per cui mp-QP$_z$ ammette una soluzione ammissibile
  $\Rightarrow$ cerchiamo x_0 tale che:

$$\begin{array}{ll} 1. & Tx_0 \leqslant Z \\ 2. & \exists z_0 : Gz_0 \leqslant W + Mx_0 \end{array} \quad \Rightarrow \quad \begin{array}{l} \max_{x,z,\alpha} \alpha \\ s.t. \; T^i x + \alpha \| T^i \| \leqslant Z^i \\ \quad Gz - Sx \leqslant W \\ \text{Centro di Chebyshev} \end{array}$$

Allora:

- risolviamo mp-QP$_z$ per $x = x_0$, ottenendo la soluzione ottima z_0
- dal momento che H è definita positiva, z_0 è unica
- z_0 determina *univocamente* un sottoinsieme di vincoli **attivi**

$$Gz_0 \leqslant W + Mx_0 \quad \Leftrightarrow \quad \begin{array}{lcl} \tilde{G}z_0 & = & \tilde{W} + \tilde{M}x_0 \\ \hat{G}z_0 & < & \hat{W} + \hat{M}x_0 \end{array}$$

$\Rightarrow \tilde{G}$, $\tilde{W}$ e $\tilde{M}$ caratterizzano i vincoli attivi della soluzione ottima z_0 a x_0!

Struttura della soluzione ottima di mp-QP$_z$ (2/2)

Struttura di $z^\star(x)$

Supponiamo che le righe di $\tilde{G}$ siano linearmente indipendenti. Sia CR_0 (**regione critica**) l'insieme di tutti i vettori x per i quali la stessa combinazione di vincoli è attiva all'ottimo $z^\star(x)$. Allora $z^\star(x)$ è una funzione **affine** di x univocamente definita in CR_0 e data da

$$z^\star(x) = H^{-1}\tilde{G}^\top(\tilde{G}H^{-1}\tilde{G})^{-1}(\tilde{W} + \tilde{M}x)$$

per ogni $x \in CR_0$. ◦

dimostrazione: Sia $\lambda \in \mathbb{R}^q$ il moltiplicatore di Lagrange del problema di ottimizzazione vincolata mp-QP$_z$, allora le condizioni al primo ordine di **Karush-Kuhn-Tucker** sono[7]:

(1) $Hz + G^\top\lambda = 0$ (derivata funzione Lagrangiana)

(2) $\lambda_i(G^i z - W^i - M^i x) = 0$, $i = 1, \ldots, q$ (condizioni di complementarietà)

(3) $\lambda_i \geqslant 0$, $i = 1, \ldots, q$ (condizioni di non-negatività)

(4) $Gz \leqslant W + Mx$ (condizioni di ammissibilità)

da (1) $\Rightarrow z = -H^{-1}G^\top\lambda$ e, sostituendo in (2)

$$\lambda^\top(-GH^{-1}G^\top\lambda - W - Mx) = 0 \qquad (\textit{continua...})$$

[7] A^i rappresenta la riga i-esima della generica matrice A

Struttura della soluzione ottima di mp-QP$_z$ (2/2)

Struttura di $z^\star(x)$

Supponiamo che le righe di $\tilde{G}$ siano linearmente indipendenti. Sia CR_0 (**regione critica**) l'insieme di tutti i vettori x per i quali la stessa combinazione di vincoli è attiva all'ottimo $z^\star(x)$. Allora $z^\star(x)$ è una funzione **affine** di x univocamente definita in CR_0 e data da

$$z^\star(x) = H^{-1}\tilde{G}^\top(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}(\tilde{W} + \tilde{M}x)$$

per ogni $x \in CR_0$. ◦

dimostrazione: (...) siano $\hat{\lambda}$ e $\tilde{\lambda}$ i moltiplicatori di vincoli non-attivi e attivi, rispettivamente. Allora

$\Rightarrow \hat{\lambda} = 0$ (da (2) e $\hat{G}z - \hat{W} - \hat{M}x < 0$)

$\Rightarrow$ per i vincoli attivi $\tilde{G}z - \tilde{W} - \tilde{M}x = 0$ implica

$$-\tilde{G}H^{-1}\tilde{G}^\top\tilde{\lambda} - \tilde{W} - \tilde{M}x = 0 \quad \Rightarrow \tilde{\lambda} = -(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}(\tilde{W} + \tilde{M}x)$$

Quindi $\lambda = (\tilde{\lambda}, \hat{\lambda}) = (-(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}(\tilde{W} + \tilde{M}x), 0)$, che sostituito in (1) fornisce $z^\star$. □

Definizione della regione critica CR_0

Abbiamo visto che in *qualche* intorno di x_0 la soluzione $z^\star(x)$ e i corrispondenti moltiplicatori sono funzioni affini di x

Ora vogliamo **caratterizzare** esplicitamente la regione critica CR_0

Imponiamo ammissibilità *primale* e *duale*, ovvero

$$\text{i)}\ \overbrace{G\,H^{-1}\tilde{G}^\top(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}(\tilde{W}+\tilde{M}x)}^{=z(x)} \leqslant W+Mx\ \text{(ammissibilità)} \Leftrightarrow \hat{G}z(x)\leqslant \hat{W}+\hat{M}x$$

$$\text{ii)}\ \underbrace{-(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}(\tilde{W}+\tilde{M}x)}_{=\tilde{\lambda}(x)} \geqslant 0\ \text{(vincolo di non-negatività)}$$

$\Rightarrow$ vincoli lineari in x!

Quindi

$$CR_0 := \{x \in X : A_0 x \leqslant b_0\}$$

con A_0, b_0 ottenute da *i)* e *ii)* dopo aver eliminato vincoli **ridondanti**

CR_0 è un sottoinsieme **poliedrale** di X!

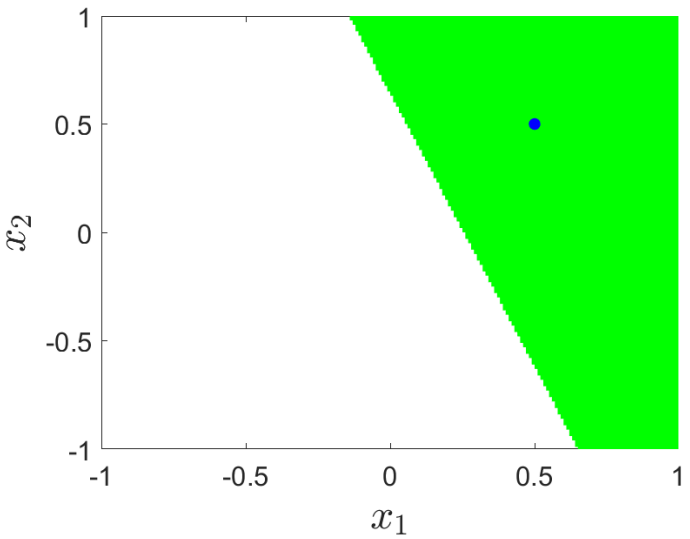
Esempio di calcolo di $z^\star(x)$ e CR_0

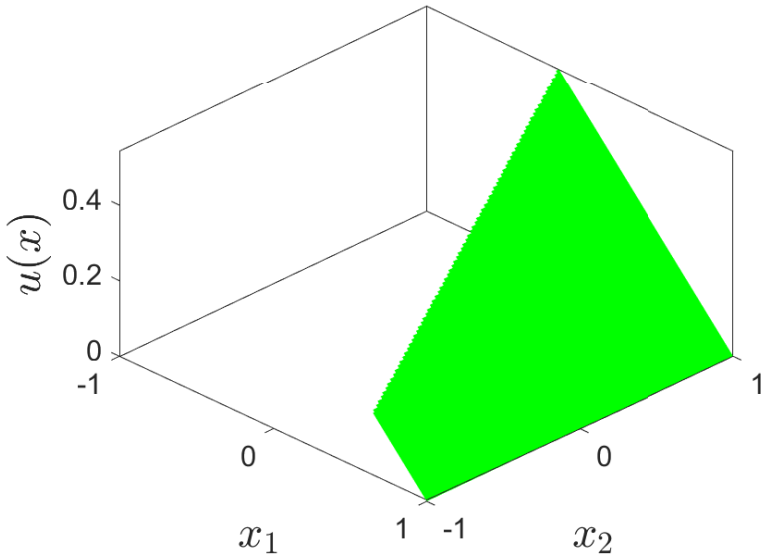
Consideriamo l'esempio del doppio integratore:

1) Fissiamo $X := \{-1 \leqslant x_1 \leqslant 1,\ -1 \leqslant x_2 \leqslant 1\}$ e $x_0 \in X$
2) Calcoliamo $z^\star(x_0)$ tramite **fmincon** in Matlab
3) Determiniamo i vincoli attivi $\tilde{G}$, $\tilde{W}$ e $\tilde{M}$ e

$$A_0 = \begin{bmatrix} GH^{-1}\tilde{G}^\top(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}\tilde{M} - M \\ (\tilde{G}H^{-1}\tilde{G}^\top)^{-1}\tilde{M} \end{bmatrix}, \quad b_0 = \begin{bmatrix} W - GH^{-1}\tilde{G}^\top(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}\tilde{W} \\ -(\tilde{G}H^{-1}\tilde{G}^\top)^{-1}\tilde{W} \end{bmatrix}$$

4) Rappresentiamo CR_0 come l'insieme $\{x \in X : A_0 x \leqslant b_0\}$
5) la soluzione ottima $u^\star(x)$ in CR_0 è $u^\star(x) = [I, 0, ..., 0](z^\star(x) - H^{-1}Fx)$





Esplorazione di $X \setminus CR_0$

Dopo aver calcolato CR_0 (e la corrispondente soluzione ottima $u^\star(x)$), definiamo

$$CR_{\text{rest}} = X \setminus CR_0$$

ovvero la regione di X non inclusa in CR_0 (su cui ancora non conosciamo la soluzione)

$\Rightarrow$ **Iteriamo**, calcolando una regione critica in sottoinsiemi poliedrali di CR_{rest}!

Come possiamo procedere con l'esplorazione di CR_{rest}?

Decomposizione poliedrale

Sia X un poliedro e $CR_0 := \{x \in X : Ax \leqslant b\}$ sottoinsieme di X, $CR_0 \neq \emptyset$. Inoltre, siano $R_i = \{x \in X : A^i x > b^i, A^j x \leqslant b^j, \forall j < i\}$, $i = 1, ..., dim(b)$ e sia $CR_{\text{rest}} = \bigcup_{i=1}^{dim(b)} R_i$. Allora

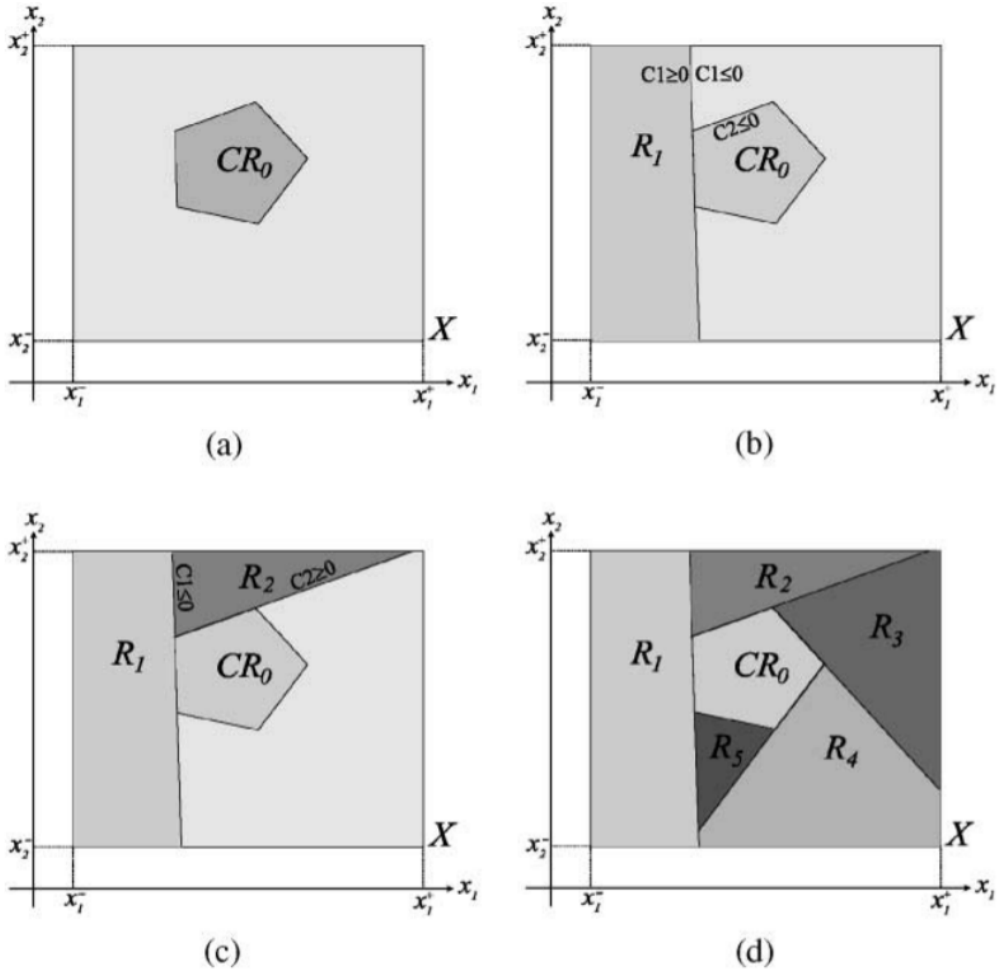
(i) $CR_{\text{rest}} \cup CR_0 = X$

(ii) $CR_0 \cap R_i = \emptyset$, $R_i \cap R_j = \emptyset$, $\forall i \neq j$

$\Rightarrow \{CR_0, R_1, ..., R_{dim(b)}\}$ è una **partizione** di X

Esplorazione di $X \setminus CR_0$

Violiamo iterativamente un vincolo alla volta



[1] The explicit linear quadratic regulator for constrained systems, A. Bemporad et al., Automatica, vol. 38, pp. 3-20, 2002

Dimostrazione della decomposizione

(i): dato $x \in X$, vogliamo dimostrare che appartiene o a CR_0 o a CR_{rest} (ovvero a R_i per qualche i):

- Se $x \in CR_0$, la conclusione è ovvia;
- Se $x \notin CR_0$, esiste un indice i tale che $A^i x > b^i$. Sia $i^\star = \min_{i \leqslant dim(b)} \{i : A^i x > b^i\}$. Allora $x \in R_{i^\star}$, in quanto $A^j x \leqslant b^j$ per ogni $j < i^\star$, per definizione di $i^\star$

(ii):

- Sia $x \in CR_0$, allora non esiste i tale che $A^i x > b^i \Rightarrow x \notin R_i$ per nessuna i
- Sia $x \in R_i$ e prendiamo $i > j$. Dal momento che $x \in R_i$, per definizione di R_i, $A^j x \leqslant b^j$, che implica $x \notin R_j$

Nelle prossime lezioni...

Ci chiediamo cosa possiamo fare nel caso in cui non abbiamo una conoscenza esatta del modello

Prossimi passi:

- studiamo il Reinforcement Learning
- Programmazione Dinamica basata su dati raccolti e *rewards* per azioni compiute

Nelle prossime lezioni...

Ci chiediamo cosa possiamo fare nel caso in cui non abbiamo una conoscenza esatta del modello

Prossimi passi:

- studiamo il Reinforcement Learning
- Programmazione Dinamica basata su dati raccolti e *rewards* per azioni compiute