Funzioni Valore nel Reinforcement Learning

a.a. 2024/2025

Mario Sassano

Dipartimento di Ingegneria Civile e Ingegneria Informatica
Università di Roma Tor Vergata

Nelle lezioni precedenti...

- Abbiamo introdotto il Reinforcement Learning e i suoi ingredienti principali

• Voglio anno evitare di conoscere a priori la x_{k+1} (non conosco $f: X \times U \to X$)

• Evito di conoscere la $p: X \times U \to p$ ⇒ conosco solo R_{k+1}.

Funzione Valore di stato

Tutti gli algoritmi di RL si basano sulla **stima** della Funzione Valore

$v_\pi(x)$: Funzione Valore di stato (state Value Function) per la policy π

Nella PD $V_k(x_k)$ dava l'ottimo di LP; qui la f.ne valore è relativa alla politica π

Valore di π da x

La Funzione Valore $v_\pi : X \to \mathbb{R}$ fornisce il *valore* (ricavo complessivo) di uno stato $x \in X$

$$v_\pi(x) = G_k(x) = \sum_{i=0}^{\infty} \gamma^i R_{k+i+1}$$

La Funzione Valore $v_\pi(x)$ dipende da:

- stato corrente $x \in X$
- politica decisionale (*policy*) $\pi : X \to U$

Le *ricompense* R_{k+i+1} sono ottenute ad ogni passo "seguendo" la policy π, **ovvero** in maniera unica e deterministica

$$\underbrace{u_k = \pi(x) \Rightarrow \begin{cases} x_{k+1} = f(x, \pi(x)) \\ R_{k+1} = \varrho(x, \pi(x)) \end{cases}}_{\text{passo } k} \Longrightarrow \underbrace{u_{k+1} = \pi(x_{k+1}) \Rightarrow \begin{cases} x_{k+2} = f(x_{k+1}, u_{k+1}) \\ R_{k+2} = \varrho(x_{k+1}, u_{k+1}) \end{cases}}_{\text{passo } k+1} \Longrightarrow \dots$$

TRANSIGE LO STATO IN x_{k+1}

OTTENGO UN GUADAGNO

lo metto nella $V_\pi(x)$.

Perché non avevamo associato la $V(\cdot)$ alle π? Nella PD, conoscendo Σ e gli altri elementi in maniera esatta avevamo risolto il problema senza iterare sfruttando Bellman.

↓

serve conoscere $g: X \times U \to \mathbb{R}$ e $f: X \times U \to X$ non posso risolvere Bellman esplicitamente.

Nel RL si usa una procedura iterativa che si basa sul miglioramento del valore di una politica decisionale π (a partire dallo stato x).

↓

per questo ho la dipendenza da π.

$$V_\pi(x) = G_k(x) = \sum_{i=0}^{+\infty} \gamma^i \cdot R_{k+i+1}.$$

Date una politica $\pi: X \to U$ ne calcolo il valore.

Equazione del valore di v_π

l'equazione $v_\pi(k) = \sum_{i=0}^{+\infty} \gamma^i R_{k+i+1}$ è scomoda operativamente (somma di termini non è mai pratico)

La funzione valore soddisfa una condizione di *consistenza* ricorsiva

$$v_\pi(x) = G_k(x) = \sum_{i=0}^{\infty} \gamma^i R_{k+i+1} = R_{k+1} + \sum_{i=1}^{\infty} \gamma^i R_{k+i+1}$$

$$= R_{k+1} + \gamma \sum_{i=0}^{\infty} \gamma^i R_{k+i+2} \quad \longrightarrow \text{è } v_\pi(x_{k+1}) = R_{k+1} + \gamma R_{k+2} + \dots + \gamma^s R_{k+s} \dots$$

$$= \underbrace{R_{k+1}}_{\varrho(x,\pi(x))} + \gamma v_\pi(\underbrace{f(x,\pi(x))}_{\downarrow}) = R_{k+1} + \gamma v_\pi(x_{k+1})$$

futuro ad un passo di x noto $f(\cdot)$ e ovviamente $\pi(\cdot)$ da cui siamo partiti

Equazione del valore di v_π

Differenze con Equazione di Bellman per la Funzione Valore (ottima)?

Sono successe due cose con la consistenza ricorsiva:

1) SPARISCE LA SOMMATORIA INFINITA

2) NON HO PIÙ UN ASSEGNATORE (se non conosco $V_\pi(x_{k+1})$ come lo calcolo). ED È UN' EQUAZIONE RICORSIVA IMPLICITA ⇒ NON AVENDO IL TERMINE POSSO CMQ RISOLVERLA COME EQ. LINEARE (+ facile rispetto a Bellman)

→ In Bellman si aveva un minimo nelle def. ⇒ sto cercando un minimo (che è quello che rende complessa l'eq. stessa).
Qui, essendo $\pi(\cdot)$ assunta nota, non ho un minimo (non devo scegliere la u_k). Noto $\pi(\cdot)$ non mi pongo il problema della decisione ottima e del valore (Bellman) ma solo il valore (+ facile).

Soluzione dell'equazione del valore di v_π (1/2)

Assunzione

L'insieme degli stati ammissibili X ha cardinalità finita, $|X| = m$

L'equazione per il *valore di* π è **lineare** e può essere risolta in forma chiusa

Infatti, **data una policy** $\pi : X \to U$

$\Rightarrow$ la transizione da uno stato all'altro è fissata univocamente $x_{k+1} = f(x_k, \pi(x_k))$

(*) *ad esempio*, se ci troviamo nello stato 2 il successore è determinato da $f(2, \pi(2)) = 4$

$\Rightarrow$ la ricompensa ottenuta è fissata univocamente $R_{k+1} = \varrho(x_k, \pi(x_k))$

ad esempio, se ci troviamo nello stato 2 la ricompensa è determinata da $\varrho(2, \pi(2)) = 1$

Dunque, *ad esempio*, l'equazione del valore di v_π per $x = 2$ è

$$v_\pi(2) = 1 + \gamma v_\pi(4)$$ sistema lineare

(*) nell'esempio il fatto che da 2 vado in 4 è dovuto da $\pi(\cdot)$

Soluzione dell'equazione del valore di v_π (2/2)

$$\boxed{v_\pi(2) = 1 + \gamma v_\pi(4)}$$

ovvero

$$v_\pi(2) = 1 + \gamma \overbrace{[0, 0, 0, 1, 0, \ldots]}^{\text{dipende da } \pi} \begin{bmatrix} v_\pi(1) \\ v_\pi(2) \\ v_\pi(3) \\ v_\pi(4) \\ \vdots \end{bmatrix} \leftarrow \text{tanti elementi quanto sono gli stati.}$$

Devo scrivere le $v_\pi(x) \quad \forall x \in X \quad [|X| = m]$

Definiamo **matrice di transizione** $\mathcal{T}_\pi$ e il vettore delle ricompense $\mathcal{R}_\pi$:

- La riga i-esima di $\mathcal{T}_\pi$ ha 1 nella colonna $f(i, \pi(i))$ e 0 altrimenti
- la riga i-esima del vettore $\mathcal{R}_\pi$ è uguale a $\varrho(i, \pi(i))$

Quindi

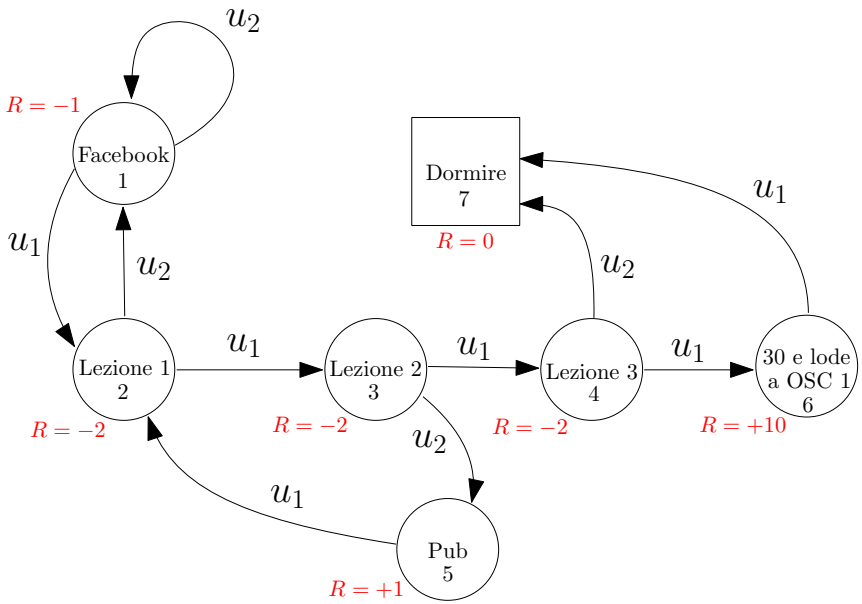
$$v_\pi(x) = R_{k+1} + \gamma v_\pi(x_{k+1}), \forall x \in X \quad \Leftrightarrow \quad \mathbf{v} = \mathcal{R}_\pi + \gamma \mathcal{T}_\pi \mathbf{v} \quad \Rightarrow \quad \mathbf{v} = \underbrace{(I - \gamma \mathcal{T}_\pi)}^{-1} \mathcal{R}_\pi$$

se $\gamma < 1$ questa matrice è invertibile (si dimostra)

dove $\mathbf{v} = [v_\pi(1), v_\pi(2), \ldots., v_\pi(m)]^\top$

Esempio: valore del comportamento dello studente (1/4)

PROCESSO MARKOVIANO => RAPPRESENTO UN SISTEMA DINAMICO A STATI FINITI



Supponiamo $\gamma = 0.5$

SUPPONIAMO CHE $\tilde{\pi}(x) = u_1$

studente giudizioso, $\pi(x) = u_1, \ \forall x \in X$

$$
\begin{cases}
v_\pi(1) = -1 + \gamma v_\pi(2) \\
v_\pi(2) = -2 + \gamma v_\pi(3) \\
v_\pi(3) = -2 + \gamma v_\pi(4) \\
v_\pi(4) = -2 + \gamma v_\pi(6) \\
v_\pi(5) = 1 + \gamma v_\pi(2) \\
v_\pi(6) = 10 + \gamma v_\pi(7) \\
v_\pi(7) = 0
\end{cases}
$$

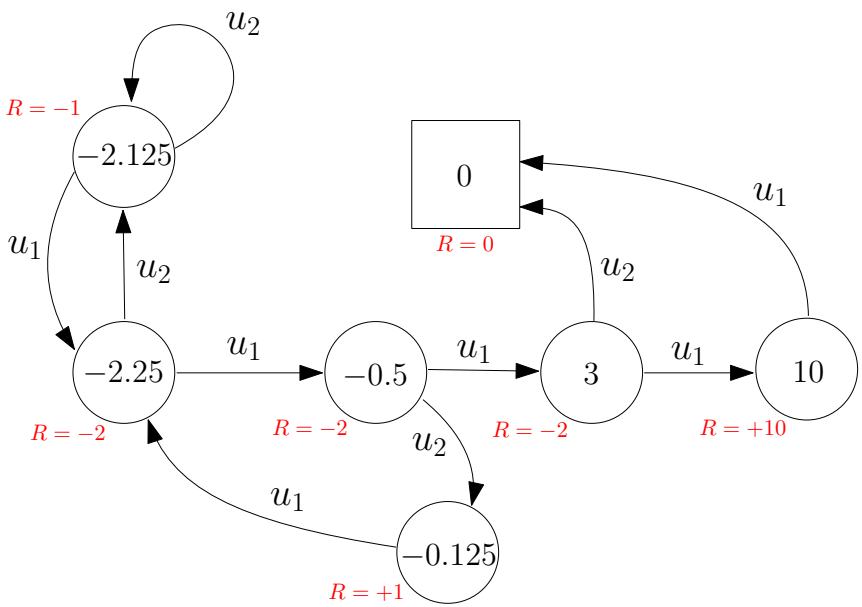
Problema decisionale a episodi => mi conviene sempre dove vado.

$$
\mathcal{T}_\pi = \begin{bmatrix}
0 & 1 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 1 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 1 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 1 & 0 \\
0 & 1 & 0 & 0 & 0 & 0 & 0 \\
0 & 0 & 0 & 0 & 0 & 0 & 1 \\
0 & 0 & 0 & 0 & 0 & 0 & 0
\end{bmatrix}, \quad
\mathcal{R}_\pi = \begin{bmatrix} -1 \\ -2 \\ -2 \\ -2 \\ 1 \\ 10 \\ 0 \end{bmatrix} \Rightarrow \quad
\mathbf{v} = \begin{bmatrix} -2.125 \\ -2.25 \\ -0.5 \\ 3 \\ -0.125 \\ 10 \\ 0 \end{bmatrix}
$$

VALORE DI TROVARMI IN 1 SEGUENDO π

ADIACENZA DEL GRAFO SU $\pi(x) = u_1$

Esempio: valore del comportamento dello studente (2/4)



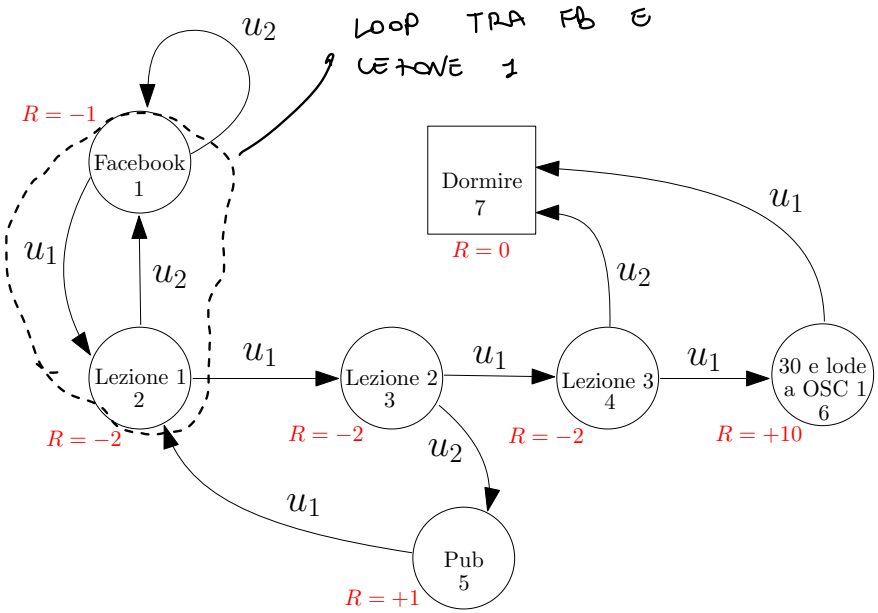
Supponiamo $\gamma = 0.5$

studente giudizioso, $\pi(x) = u_1,\ \forall x \in X$

$$\begin{cases} v_\pi(1) = -1 + \gamma v_\pi(2) \\ v_\pi(2) = -2 + \gamma v_\pi(3) \\ v_\pi(3) = -2 + \gamma v_\pi(4) \\ v_\pi(4) = -2 + \gamma v_\pi(6) \\ v_\pi(5) = 1 + \gamma v_\pi(2) \\ v_\pi(6) = 10 + \gamma v_\pi(7) \\ v_\pi(7) = 0 \end{cases}$$

$$\mathcal{T}_\pi = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}, \quad \mathcal{R}_\pi = \begin{bmatrix} -1 \\ -2 \\ -2 \\ -2 \\ 1 \\ 10 \\ 0 \end{bmatrix} \Rightarrow \quad \mathbf{v} = \begin{bmatrix} -2.125 \\ -2.25 \\ -0.5 \\ 3 \\ -0.125 \\ 10 \\ 0 \end{bmatrix}$$

Esempio: valore del comportamento dello studente (3/4)



Supponiamo $\gamma = 0.5$

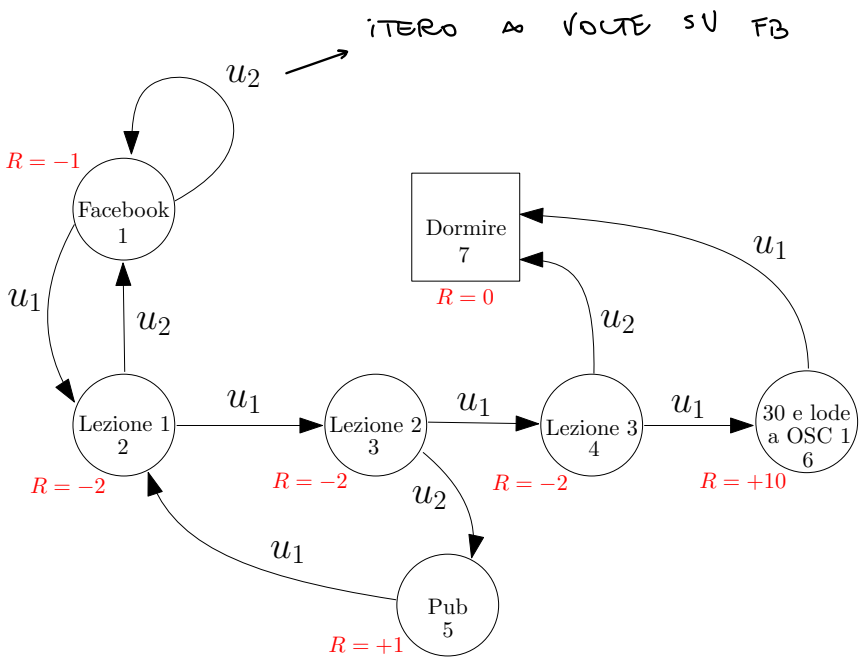
studente con rimorsi, $\pi(x) = u_1$, per $x \in \{1, 5\}$, e $\pi(x) = u_2$, per $x \in \{2, 3, 4\}$

$$\begin{cases} v_\pi(1) = -1 + \gamma v_\pi(2) \\ v_\pi(2) = -2 + \gamma v_\pi(1) \\ v_\pi(3) = -2 + \gamma v_\pi(5) \\ v_\pi(4) = -2 + \gamma v_\pi(7) \\ v_\pi(5) = 1 + \gamma v_\pi(2) \\ v_\pi(6) = 10 + \gamma v_\pi(7) \\ v_\pi(7) = 0 \end{cases}$$

$$\mathcal{T}_\pi = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}, \quad \mathcal{R}_\pi = \begin{bmatrix} -1 \\ -2 \\ -2 \\ -2 \\ 1 \\ 10 \\ 0 \end{bmatrix} \Rightarrow \quad \mathbf{v} = \begin{bmatrix} -2.667 \\ -3.33 \\ -2.33 \\ -2 \\ -0.667 \\ 10 \\ 0 \end{bmatrix}$$

VARIA RISPETTO ALLE ALTRE POLITICHE POSSIBILI

Esempio: valore del comportamento dello studente (4/4)



Supponiamo $\gamma = 0.5$

studente che si diverte, $\pi(x) = u_2$, per ogni x tranne il Pub

$$\begin{cases} v_\pi(1) = -1 + \gamma v_\pi(1) \\ v_\pi(2) = -2 + \gamma v_\pi(1) \\ v_\pi(3) = -2 + \gamma v_\pi(5) \\ v_\pi(4) = -2 + \gamma v_\pi(7) \\ v_\pi(5) = 1 + \gamma v_\pi(2) \\ v_\pi(6) = 10 + \gamma v_\pi(7) \\ v_\pi(7) = 0 \end{cases}$$

$$\mathcal{T}_\pi = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}, \quad \mathcal{R}_\pi = \begin{bmatrix} -1 \\ -2 \\ -2 \\ -2 \\ 1 \\ 10 \\ 0 \end{bmatrix} \quad \Rightarrow \quad \mathbf{v} = \begin{bmatrix} -2 \\ -3 \\ -2.25 \\ -2 \\ -0.5 \\ 10 \\ 0 \end{bmatrix}$$

In questo ultimo esempio se γ fosse 1

$$V_\pi(1) = -1 + V_\pi(1) \cdot \gamma \iff V_\pi(1) = -1 + V_\pi(1) \quad \text{impossibile}$$

Il fatto che il sistema non sia risolubile è corretto poiché

$$G_\pi(1) = -\infty \quad (\text{con} \quad \gamma = 1)$$

Con $\gamma = 0.5$ la Σ di $G_\pi(x)$ converge (serie geometrica) e la def. operativa che mi porta alla forma chiusa può essere risolta

↓

Con $\gamma = 1$ la $(I - \gamma T_\pi)$ potrebbe non essere invertibile poiché $G_\pi(x)$ diverge.

Funzione Valore di stato/azione

→ consente di valutare le diff. di diverse azioni in x a parità di azioni successive (lungo $\pi(\cdot)$)

Possiamo definire anche il *valore di una azione* da un certo stato

$q_\pi(x, u)$: Funzione Valore di stato/azione (state/action Value Function) per la policy π

Il primo passo è diverso (non è $\pi(x)$ ma u).

Valore dell'azione u con π da x

La Funzione Valore di stato/azione $q_\pi(x, u) : X \times U \to \mathbb{R}$ è definita da

$$q_\pi(x, u) = G_k(x)\Big|_{u_k = u} = R_{k+1} + \sum_{i=1}^{\infty} \gamma^i R_{k+i+1}$$

$$q_\pi(x,u) = G_k(x)\Big|_{u_k = u,\ u_{k+i} = \pi(x_{k+i})}$$

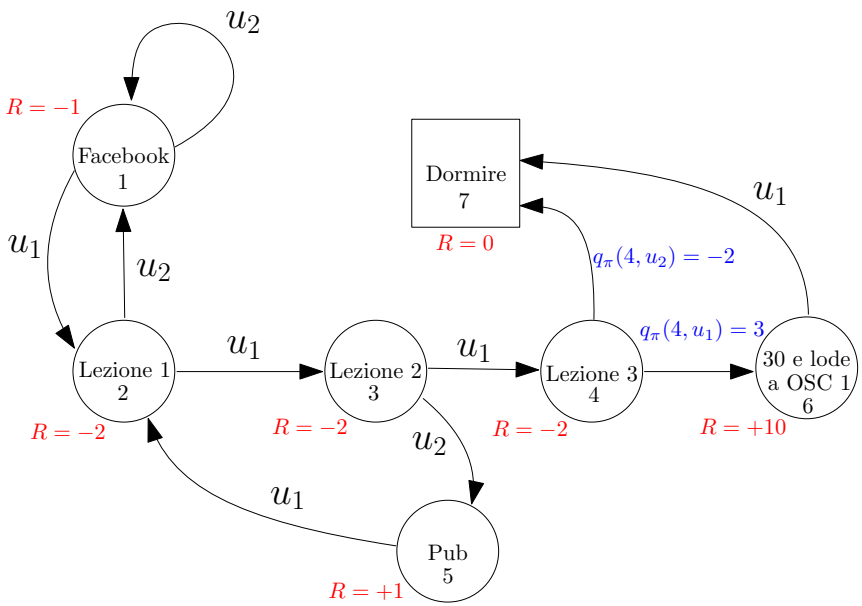
$$= \varrho(x, u) + \gamma v_\pi(x_{k+1})$$

Notiamo che:

- La *ricompensa* R_{k+1} è ottenuta implementando l'azione u
- Le *ricompense* successive R_{k+i+1}, $i \geq 1$, sono ottenute seguendo la *policy* π dallo stato $x_{k+1} = f(x, u)$ in poi

Dobbiamo capire prima come utilizzare la funzione v_π o q_π e poi come stimare le funzioni da dati raccolti!

Esempio: Funzione Valore di stato/azione



Supponiamo $\gamma = 0.5$

studente che si diverte, $\pi(x) = u_2$, per ogni x tranne il Pub

Consideriamo lo stato 4 (Lezione 3), il cui valore è -2 secondo π

$$\begin{cases} q_\pi(4,u_1) = -2 + \gamma v_\pi(6) = -2 + 0.5 \cdot 10 = 3 \\ q_\pi(4,u_2) = -2 + \gamma v_\pi(7) = -2 = v_\pi(4) \end{cases}$$

ESTO SEGUENDO LA $\pi(\cdot)$ A PARTIRE GIÀ DA 4

valuto entrambe le possibili alternative (a partire da tutte le stati future per le quali varrà $v_\pi(x_{t+1})$)

Notiamo che $q_\pi(4,u_1) > v_\pi(4)$! $\Rightarrow$ forse converrebbe sostituire $\pi(4)$ con u_1...

cambiando la scelta ad un passo da 4 potrei avere un vantaggio.

Funzione Valore ottima → vogliamo avere degli algoritmi per trovare le due f.ni

La Funzione Valore v_π permette un **ordinamento parziale**[1] delle policy.

$$\pi \geqslant \pi' \quad \Leftrightarrow \quad v_\pi \geqslant v_{\pi'}, \forall x \in X.$$

Definiamo la policy ottima e la Funzione Valore ottima corrispondente

$$\boxed{v_\star(x) = \max_\pi v_\pi(x)}$$ ← queste è la f.ne valore corrispondente alla politica decisionale ottima che va valutata su x tra le varie π.

$\Rightarrow$ massimo ricavo ottenibile da x...

Definiamo la Funzione Valore ottima di stato/azione

$$\boxed{q_\star(x,u) = \max_\pi q_\pi(x,u) = R_{k+1} + \gamma v_\star(x_{k+1})}$$ ← Bellman

$\Rightarrow$ massimo ricavo ottenibile da x, dopo aver eseguito u al tempo k...

[1] Abbiamo un ordinamento parziale perchè richiediamo che la disuguaglianza sia vera per ogni x: quindi per alcune coppie π, π' non vale nè che $\pi \geqslant \pi'$ nè $\pi' \geqslant \pi$

Policy ottima

Se conosciamo $v_\star$:

$$u_k \in \arg\max_u \{\overbrace{R_{k+1} + \gamma v_\star(f(x,u))}^{q_\star(x,u)}\}, \qquad \forall x \in X \tag{1}$$

DEVO CONOSCERE NECESSARIAMENTE CONOSCERE $f(\cdot)$ E $p(\cdot)$

$\Rightarrow$ strategia **greedy** rispetto a $v_\star$ e R_{k+1} (come per le PD).

Se conosciamo $q_\star$:

$$u_k \in \arg\max_u q_\star(x,u), \qquad \forall x \in X$$

USO IN ENTRAMBE LE EXP. u_k è ... POICHÈ L'OTTIMO NON È UNICO.

NON DEVO CONOSCERE NÈ $f(\cdot)$ NÈ $p(\cdot)$ SE QUALCUNO MI FORNISCE $q_\star(x,u)$

$\Rightarrow$ strategia **greedy** rispetto a $q_\star$

Commenti

- Maggiore *costo* di memoria per salvare valori di ciascuna coppia (x,u) → $q_\star$ È SIA SU x CHE SU u
- Non dobbiamo conoscere nulla di successori, $f(x,u)$, o ricompense, R_{k+1}!

Se riesco a stimare $q_\star(x,u)$ con un alg. sono a cavallo → alg. RL

Nelle prossime lezioni...

Siamo interessati a caratterizzare la funzione $q_\star$, la cui conoscenza *risolve* il problema decisionale con RL

Prossimi passi:

- conoscendo il modello, definiamo tecniche iterative che permettano di stimare o calcolare le funzioni v_π e q_π
- studiamo strategie che permettano di migliorare iterativamente il valore di uno stato per una policy fissata
- eseguiamo i passi precedenti in assenza di un modello, ovvero senza conoscere f e ϱ ma solo il valore R_{k+1}