Processi Decisionali di Markov Stocastici

a.a. 2022/2023

Mario Sassano

Dipartimento di Ingegneria Civile e Ingegneria Informatica
Università di Roma Tor Vergata

Nelle lezioni precedenti...

- Abbiamo introdotto la definizione di Processo Decisionale Markoviano deterministico
- Abbiamo studiato le tecniche di *Policy Evaluation* e *Policy Iteration* per valutare e migliorare, rispettivamente, il ricavo ottenuto seguendo una policy
- Abbiamo visto che anche troncando PE ad un numero finito di iterazioni otteniamo convergenza alla soluzione ottima (*Value Iteration*)

↳ l'eq. di Bellman diventa una legge di aggiornamento.

↓

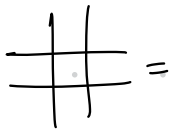
al limite una sola iterazione

PE e PI dipendono ancora dal modello ⇒ vogliamo una generalizzazione.

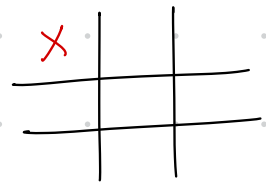
Il caso stocastico può essere usato anche per gioco differenziale, in cui ho un avversario che "altera" la risposta del modello.

ES: Alg di RL per "TIC-TAC-TOE"

Stato: "config. attuale delle tabelle"

x_0 =  = "tabelle vuote"

u_0 = "metti X nella casella in alto a sx":



Non conosco però x_1 in quanto l'avv. metterà un O in uno degli 8 spaz vuoti; supponiamo che l'avversario abbia uguale prob. di mettere il O in uno degli spaz vuoti.

Ci sono 8 possibili stati x_1 a cui posso transire con prob = 1/8

↓

lavoreremo sul concetto di valore atteso.

(Brevissimo) Richiamo su Variabili Aleatorie (1/3)

Definiamo la terna $(\Omega, \mathcal{A}, Pr)$ come **Spazio di Probabilità** dove:

- Ω, spazio campionario (sample space) → insieme che contiene tutti i possibili esiti dell'esperimento.
- $\mathcal{A}$, spazio degli eventi (insieme di sottoinsiemi di Ω)
- Pr, misura di probabilità per gli eventi in $\mathcal{A}$

per ogni evento $A \in \mathcal{A}$, definiamo

$$Pr[A], \textbf{ probabilità di A}$$

Assiomi:

- $Pr[A] \geqslant 0$, per ogni evento $A \in \mathcal{A}$
- $Pr[\Omega] = 1$
- $Pr[A_1 \cup A_2 \cup A_3 \cup ...] = Pr[A_1] + Pr[A_2] + Pr[A_3] + ...$, per eventi disgiunti

(Brevissimo) Richiamo su Variabili Aleatorie (2/3)

Consideriamo Spazi di Probabilità **discreti** (Ω numerabile o **finito**):

$$\Omega = \{\omega_1, \omega_2, \ldots, \omega_N\}$$ non solo numerabile ma anche finito.

Esempio. Lancio di due dadi

$\Omega := \{(i,j) : 1 \leqslant i \leqslant 6, 1 \leqslant j \leqslant 6\}$

$\mathcal{A}$ è l'insieme di tutte le possibili coppie di valori per i e j: $(1,1), (1,2), \ldots$

ogni coppia ha probabilità pari a $\frac{1}{36} = p_{11} = p_{12} = \ldots$

un *evento* può essere un qualsiasi sottoinsieme di Ω (e la probabilità è la somma..)

doppi: $p_{11} + p_{22} + \ldots + p_{66} = 1/6$

dado più alto $= 3$: $p_{13} + p_{23} + p_{33} + p_{32} + p_{31} = 5/36$

Probabilità condizionata: confronta la probabilità di un evento con quella dello stesso evento *data* informazione aggiuntiva

sfrutto le misure già introdotta.

nuova funzione tecnicamente

$$Pr[A|B] \coloneqq \frac{Pr[A \cap B]}{Pr[B]}$$

"Formule di Bayes".

Esempio. Sia A l'evento "somma $\geqslant 7$" e B "un dado $\geqslant 5$", calcolare $Pr[A]$ e $Pr[A|B]$...

(Brevissimo) Richiamo su Variabili Aleatorie (3/3)

Variabile Aleatoria Discreta X: dato uno Spazio di Probabilità Discreto $(\Omega, \mathcal{A}, Pr)$, X è una funzione da Ω in $\mathbb{R}$ (Associa all'esito un valore).

$$x = X(\omega) \longrightarrow$$ altro modo per caratterizzare (in modo compatto) un evento.

$\Rightarrow X(\cdot)$ è la funzione (Variabile Aleatoria) e x è il valore

$\Rightarrow X$ rappresenta un modo più semplice di rappresentare eventi...

Esempio.

somma del lancio di due dadi $\rightarrow X(i,j) = i + j$

$X \geqslant 11 \leftrightarrow$ evento $(5,6) \cup (6,5) \cup (6,6)$

Funzione di massa di probabilità

$$p_{\underline{X}}(x) = Pr[\underline{X} = x]$$

Valore Atteso

$E[X]$, X descrive l'esito del lancio del dado $E[X] = 3.5$ $\leftarrow$

$$E[X] = \sum_x x p_X(x) \leftarrow \text{somma pesata}$$

Valore Atteso Condizionato

$$E[\underbrace{X}_{\text{nuova v.a.}}|A] = \sum_x x p_{X|A}(x), \qquad p_{X|A}(x) = Pr[X = x|A]$$

(Brevissimo) Richiamo su Variabili Aleatorie (3/3)

Variabile Aleatoria Discreta X: dato uno Spazio di Probabilità Discreto $(\Omega, \mathcal{A}, Pr)$, X è una funzione da Ω in $\mathbb{R}$

$$x = X(\omega)$$

$\Rightarrow X(\cdot)$ è la funzione (Variabile Aleatoria) e x è il valore

$\Rightarrow X$ rappresenta un modo più semplice di rappresentare eventi...

Esempio.

somma del lancio di due dadi $\rightarrow X(i,j) = i + j$

$X \geqslant 11 \rightarrow$ evento $(5,6) \cup (6,5) \cup (6,6)$

Funzione di massa di probabilità

$$p_X(x) = Pr[X = x]$$

Valore Atteso

$$E[X] = \sum_x x p_X(x)$$

Esempio X somma del lancio di due dadi

$E[X] = (1+1)p_{11} + (1+2)p_{12} + \ldots + (2+1)p_{21} + \ldots = 252/36 = 7$

non è detto che $X = 7$ sia l'evento più probabile e anzi non è così.

Processo Decisionale di Markov Stocastico

Fino ad ora abbiamo visto che, dato il valore dello stato x e l'azione u all'istante k

$\Rightarrow$ il valore dello stato successivo x' è *univocamente* fissato dal modello (deterministico) f

$$x' = f(x, u)$$

e allo stesso modo abbiamo la *certezza* di ricevere la ricompensa

$$r = R_{k+1} = \varrho(x, u)$$

$$\Downarrow$$

Gli algoritimi di Policy Evaluation, Policy Iteration, Value Iteration possono essere applicati in un contesto **non-deterministico**

Lo stato non transita, transisce.

Processo Decisionale di Markov Stocastico

La generalizzazione al contesto **stocastico** è ottenuta:

- specificando la **funzione di massa di probabilità** che lo stato successivo sia x' e la ricompensa sia r

$$p(x', r|x, u) = Pr[\mathcal{R}_{k+1} = r, \mathcal{X}_{k+1} = x'|\mathcal{X}_k = x, \mathcal{U}_k = u]$$

dove $\mathcal{R}$, $\mathcal{X}$ e $\mathcal{U}$ rappresentano variabili aleatorie discrete, da cui possiamo calcolare la **probabilità di transizione di stato**

$$p(x'|x, u) = \sum_r p(x', r|x, u)$$

(sommiamo rispetto a tutte le possibili ricompense visto che ci interessa solo lo stato successivo x'...)

- descrivendo una **policy** come una distribuzione di probabilità $\pi(u|x)$

(probabilità di eseguire un'azione u dato che il processo si trova nello stato x...)

- definendo l'**obiettivo** come la massimizzazione del valore atteso del ricavo

$$v_\pi(x) = E_\pi[G_k|\mathcal{X}_k = x] = E_\pi\left[\sum_{i=0}^{\infty} \mathcal{R}_{k+i+1}|\mathcal{X}_k = x\right]$$

Equazione del valore di π

Come si modifica l'equazione del valore della policy π?

Nel caso deterministico era...

$$v_\pi(x) = r + \gamma v_\pi(x')$$

il futuro ha una sola possibilità

(ricompensa immediata r più il valore del successore deterministico x')

x transisce sicuramente a x'.

Nel caso stocastico diventa...

$$v_\pi(x) = \sum_{x'} \sum_{r} p(x', r|x, u)[r + \gamma v_\pi(x')]$$

... a patto di aver eseguito l'azione u, ma anche questa scelta è aleatoria...

$$v_\pi(x) = \sum_{u} \pi(u|x) \sum_{x'} \sum_{r} p(x', r|x, u)[r + \gamma v_\pi(x')]$$

Valore di π da x: media tra tutte le possibili azioni dei valori attesi dei ricavi da x in poi

Equazione del valore di π

Come si modifica l'equazione del valore della policy π?

Nel caso deterministico era...

$$v_\pi(x) = r + \gamma v_\pi(x')$$

(ricompensa immediata r più il valore del successore deterministico x')

Nel caso stocastico diventa...

$$v_\pi(x) = \sum_{x'} \sum_{r} p(x', r|x, u)[r + \gamma v_\pi(x')]$$

... a patto di aver eseguito l'azione u, ma anche questa scelta è aleatoria...

$$v_\pi(x) = \sum_{u} \pi(u|x) \sum_{x'} \sum_{r} p(x', r|x, u)[r + \gamma v_\pi(x')]$$

La Funzione valore di stato/azione diventa

$$q_\pi(x, u) = \sum_{x'} \sum_{r} p(x', r|x, u)[r + \gamma v_\pi(x')]$$ ← ho la certezza di aver eseguito u.

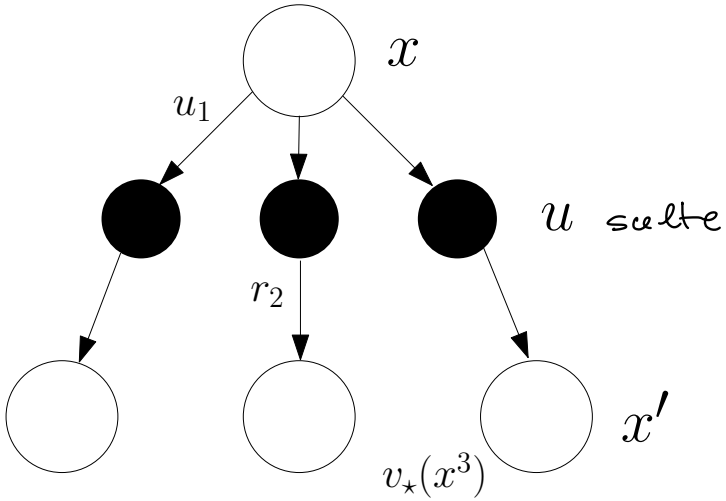
Equazione di Bellman Stocastica

Nel caso del valore ottimo $v_\star$

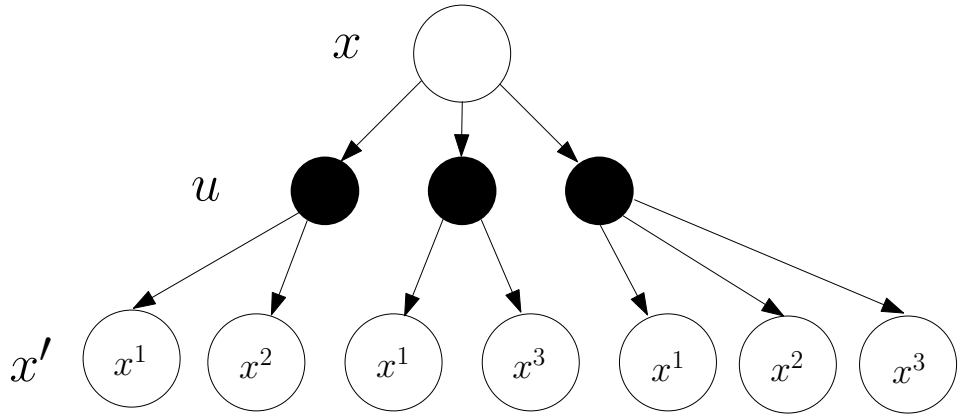
$$v_\star(x) = \max_u \underbrace{\sum_{x'} \sum_r p(x', r|x, u)[r + \gamma v_\star(x')]}_{q_\pi(x,u)}$$

scegliamo l'azione che massimizza il **valore atteso** dallo stato x all'istante k in poi

Confronto grafico con Equazione di Bellman deterministica



caso deterministico



caso stocastico

$V_\pi(x) = r + \gamma \cdot V_\pi(x') \quad ; x' = f(x,u) \quad r = p(x,u)$

Value Iteration e Policy ottima

per determinare $v_\star$ utilizziamo la Value Iteration da $v_0(x)$ (arbitraria)

$$v_{k+1}(x) = \max_u \sum_{x'} \sum_r p(x', r|x, u)[r + \gamma v_k(x')], \qquad k = 0, 1, \ldots$$

si dimostra che $\lim_{k\to\infty} v_k = v_\star$

ho ancora il modello che non è più det. ne stocast. ca.

max. che posso ottenere del valore atteso delle ricompense

Se $v_\star(x)$ è nota per ogni $x \in X$

costruiamo la policy ottima $\pi_\star(x)$:

- per ogni $x \in X$, consideriamo tutte le azioni in

$$u^\star \in \arg\max_u \sum_{x'} \sum_r p(x', r|x, u)[r + \gamma v_\star(x')]$$

∈: potrei avere più azioni che massimizzano il valore atteso.

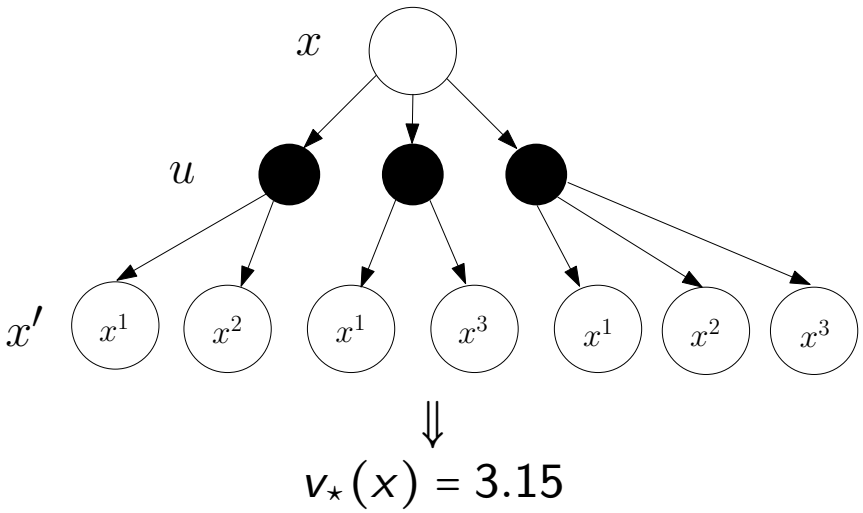
- qualsiasi policy che assegna **probabilità non nulla** solo a tali azioni è ottima
- possiamo sempre costruire una policy ottima deterministica!

↳ posso assegnare $p=1$ ad una sola delle politiche che mi conducono all'ottimo.

Esempio di Equazione di Bellman Stocastica

Supponiamo di aver già calcolato $v_\star(x^1) = 2$, $v_\star(x^2) = 1$ e $v_\star(x^3) = 0.5$

Vogliamo calcolare $v_\star(x)$ con $\gamma = 1$



$\Downarrow$

$v_\star(x) = 3.15$

Dati x e u_1

$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.2 \\ (x^2, 0.5) & \text{prob} = 0.8 \end{cases}$$

valore di u_1: $0.2(1+2)+0.8(0.5+1) = 1.8$

Dati x e u_2

$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.5 \\ (x^3, 2) & \text{prob} = 0.5 \end{cases}$$

valore di u_2: $0.5(1+2)+0.5(2+0.5) = 2.75$

Dati x e u_3

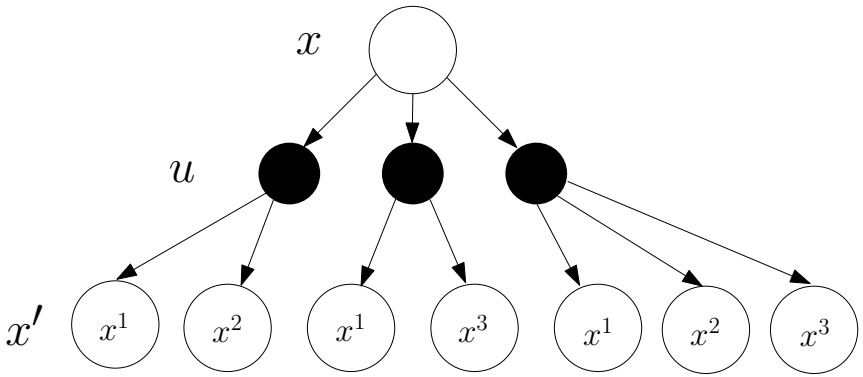
$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.4 \\ (x^2, 2) & \text{prob} = 0.3 \\ (x^3, 3) & \text{prob} = 0.3 \end{cases}$$

valore di u_3: $1.2 + 0.9 + 1.05 = 3.15$

Esempio di Equazione di Bellman Stocastica

Supponiamo che la policy π è tale che $v_\pi(x^1) = 0.5$, $v_\pi(x^2) = 3$ e $v_\pi(x^3) = 1$

Calcolare $v_\pi(x)$ e $q_\pi(x, u)$ con $\gamma = 1$, dove $\pi(u_1|x) = 0.6$, $\pi(u_2|x) = 0.3$, $\pi(u_3|x) = 0.1$



Funzione di massa di probabilità

Dati x e u_1

$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.2 \\ (x^2, 0.5) & \text{prob} = 0.8 \end{cases}$$

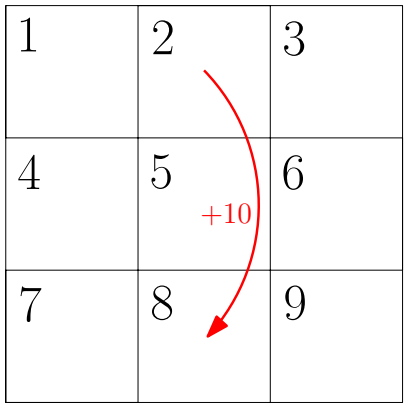
Dati x e u_2

$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.5 \\ (x^3, 2) & \text{prob} = 0.5 \end{cases}$$

Dati x e u_3

$$(x', r) = \begin{cases} (x^1, 1) & \text{prob} = 0.4 \\ (x^2, 2) & \text{prob} = 0.3 \\ (x^3, 3) & \text{prob} = 0.3 \end{cases}$$

Gridworld



- valori dello stato $X = \{1, 2, ..., 8, 9\}$
- valori dell'azione $\mathcal{A}(x) = \{\text{su}, \text{giu}, \text{destra}, \text{sinistra}\}$
- uscire dalla griglia: $r = -1$, $x' = x$
- da $x = 2$: $r = +10$, $x' = 8$
- $\gamma = 0.9$

Vogliamo calcolare il valore della policy

mi muovo a caso.

$$\pi(u|x) = \frac{1}{4}, \quad \forall x, u$$

• prob. di eseguire un'azione.

Scriviamo l'equazione di Bellman

su giù

$$\begin{cases} v_\pi(1) = \frac{1}{4}(-1 + \gamma v_\pi(1)) + \frac{1}{4}(0 + \gamma v_\pi(4)) + \frac{1}{4}(\gamma v_\pi(2)) + \frac{1}{4}(-1 + \gamma v_\pi(1)) \\ v_\pi(2) = \frac{1}{4}(10 + \gamma v_\pi(8)) + \ldots = 10 + \gamma v_\pi(8) \\ v_\pi(3) = \ldots \end{cases}$$

comunque ho un sistema lineare.

Come scrivo $\underline{V} = R_\pi + \gamma T_\pi \cdot V$? Per la PE.

$$V_\pi(1) = \frac{1}{4}(-1 + \gamma V_\pi(1)) + \frac{1}{4}(0 + \gamma V_\pi(4)) + \frac{1}{4}(0 + \gamma V_\pi(2)) + \frac{1}{4}(-1 + \gamma V_\pi(1)) =$$

$$= \underbrace{\left(-\tfrac{1}{4} + 0 + 0 - \tfrac{1}{4}\right)}_{-1/2} + \gamma \underbrace{\left[\tfrac{1}{4} + \tfrac{1}{4}, \tfrac{1}{4}, 0, \tfrac{1}{4}, 0, 0, 0, 0, 0\right]}_{\text{PRIMA RIGA } T_\pi} \begin{bmatrix} V_\pi(1) \\ V_\pi(2) \\ \vdots \\ V_\pi(9) \end{bmatrix}$$

Nel caso det. le i-esima riga di T_π avere un uno nel succ. deterministico di x_i secondo π.

↓

In questo caso la riga è più piena perché ho più successori stocastici $\underbrace{\sum_j T_\pi(i,j) = 1 \quad \forall\, i}_{\text{come nelle catene di Markov}}$.

Nelle prossime lezioni...

siamo interessati a tecniche che permettano di risolvere problemi di RL senza conoscere il modello

Prossimi passi:

- studiamo RL basato esclusivamente su esperienza e dati raccolti
- Temporal-difference learning, Q-learning